

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



Hoàng Minh Nhật

**HỆ THỐNG GỢI Ý KẾT BẠN DỰA
TRÊN TÍNH CÁCH, XỬ LÝ TRỰC TIẾP
TRÊN THIẾT BỊ ĐỂ BẢO VỆ QUYỀN
RIÊNG TƯ**

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành: Công nghệ thông tin

TP. HCM - 2025

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



Hoàng Minh Nhật

**HỆ THỐNG GỢI Ý KẾT BẠN DỰA
TRÊN TÍNH CÁCH, XỬ LÝ TRỰC TIẾP
TRÊN THIẾT BỊ ĐỂ BẢO VỆ QUYỀN
RIÊNG TƯ**

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành: Công nghệ thông tin

Cán bộ hướng dẫn: Th.S Ngô Khánh Khoa

TP. HCM - 2025

LỜI CAM ĐOAN

Khóa luận tốt nghiệp này được thực hiện trực tiếp bởi em và dưới sự hướng dẫn của thầy Thạc Sĩ Ngô Khánh Khoa. Em xin cam đoan rằng mọi quá trình nghiên cứu, phát triển, triển khai và báo cáo được trình bày trong báo cáo này đều được chính em độc lập thực hiện mà không sao chép, đạo văn từ những nguồn khác mà không có sự cho phép. Nếu có vi phạm quy định về nội dung trí tuệ, em xin chịu trách nhiệm tất cả những truy cứu theo quy định của Trường Đại Học Công Nghệ Thông Tin - ĐHQG HCM.

TpHCM, ngày 26 tháng 12 năm 2024

Sinh viên

Hoàng Minh Nhật

LỜI CẢM ƠN

Lời đầu tiên cho phép em bày tỏ lòng biết ơn sâu sắc đến Khoa Công nghệ Thông tin - Trường Đại học Công nghệ, ĐHQGHN. Đây là nơi em đã có cơ hội tiếp cận với những tri thức mới mẻ, được học hỏi từ các thầy cô xuất sắc và kết nối với những người bạn, anh chị em đầy năng động và tài năng.

Em cũng xin gửi lời cảm ơn chân thành đến cô Hoàng Thị Diệp, người đã luôn là nguồn cảm hứng và sự hướng dẫn quý báu trong suốt thời gian em học tập tại trường. Sự tận tâm và hỗ trợ nhiệt tình của cô đã tiếp thêm động lực để em vượt qua những thử thách trong hành trình nghiên cứu và hoàn thiện khóa luận tốt nghiệp.

Ngoài ra, em xin gửi lời cảm ơn đến gia đình, bạn bè và những người đã luôn giúp đỡ, động viên, đồng hành cùng em suốt chặng đường học tập ở trường và khoảng thời gian thực hiện khóa luận.

Kính chúc tất cả mọi người luôn vui vẻ, hạnh phúc và gặt hái được nhiều thành công trong cuộc sống.

TÓM TẮT

Tóm tắt: Bài toán xây dựng cây bootstrap tiến hóa (Phylogenetic bootstrapping) là một phần quan trọng trong sinh học tiến hóa, nhằm tái tạo cây tiến hóa với số lượng thay đổi tối thiểu dựa trên tiêu chí tính tiết kiệm tối đa (maximum parsimony - MP) đồng thời tính độ tin cậy của các phân hoạch nhị phân trong cây này. MPBoot2 cải tiến so với phiên bản trước, MPBoot, bằng cách tích hợp kỹ thuật biến đổi cây Tree Bisection and Reconnection (TBR), cho phép khám phá không gian cây một cách toàn diện hơn so với Subtree Pruning and Regrafting (SPR). Hai phép biến đổi này bổ trợ lẫn nhau để tăng cường khả năng khám phá không gian cây. Để nâng cao hiệu suất hơn nữa, chúng tôi giới thiệu MPBoot-RL, áp dụng giải thuật tối ưu đàn kiến (ant colony optimization) nhằm kết hợp động giữa SPR và TBR, cải thiện cả độ chính xác và thời gian chạy. MPBoot2 còn bao gồm các tính năng tiên tiến như hệ thống checkpoint, hỗ trợ nhiều loại dữ liệu khác nhau, và quản lý bộ nhớ tối ưu, giúp nó phù hợp với các tập dữ liệu lớn và phức tạp. Kết quả thực nghiệm cho thấy hiệu suất vượt trội về cả độ chính xác lẫn tốc độ thực thi, khẳng định MPBoot2 và MPBoot-RL là những công cụ đa năng và mạnh mẽ cho phân tích phát sinh chủng loại dựa trên tiêu chí MP.

Từ khóa: *MPBoot, MPBoot2, MPBoot-RL, Phát sinh chủng loại học*

MỤC LỤC

Lời cam đoan	i
Lời cảm ơn	ii
Tóm tắt	iii
Mục lục	iv
Danh mục hình ảnh	x
Danh mục bảng	xi
Danh mục giải thuật	xii
Chương 1. Giới thiệu	1
1.1. Bối cảnh và vấn đề	1
1.1.1. Mạng xã hội và nhu cầu kết nối theo tính cách	1
1.1.2. Rủi ro dữ liệu tính cách và yêu cầu bảo vệ	2
1.2. Mục tiêu và phạm vi	3
1.2.1. Mục tiêu chính	3
1.2.2. Phạm vi thực hiện	4
1.3. Bài toán và cách tiếp cận	4
1.3.1. Bài toán chuyển đổi dữ liệu tính cách	4
1.3.2. Bài toán bảo mật dữ liệu	6
1.4. Đóng góp chính	7
1.4.1. Đóng góp về mô hình chuyển đổi	7
1.4.2. Đóng góp về bảo mật	7
1.4.3. Đóng góp về tài liệu kỹ thuật và minh chứng	7
1.5. Cấu trúc của báo cáo	8
Chương 2. Tổng quan quy trình hệ thống	9

2.1. Mục tiêu của chương	9
2.2. Các nguồn dữ liệu đầu vào	9
2.2.1. Bộ câu hỏi Big Five và cách lấy mẫu	9
2.2.2. Dữ liệu khảo sát công khai cho PCA	10
2.2.3. Dữ liệu sở thích (hobbies)	10
2.3. Tổng quan quy trình và tác nhân	10
2.4. Đề xuất phân mảnh địa lý trong quy trình gợi ý	11
2.5. Mô hình điểm và trọng số trong gợi ý	12
2.5.1. Điểm tương đồng tính cách (PCA)	12
2.5.2. ELO từ tương tác like/skip	12
2.5.3. Embedding sở thích và cosine similarity	13
2.5.4. Trọng số tổng hợp	13
2.6. Luồng dữ liệu chi tiết theo tác nhân	14
2.6.1. Thiết bị người dùng	14
2.6.2. Edge Function	14
2.6.3. Cơ sở dữ liệu	15
2.7. Cấu trúc các chương tiếp theo	15
Chương 3. Chuyển đổi dữ liệu tính cách (PCA-4)	17
3.1. Mục tiêu của chương	17
3.2. Big Five trong bối cảnh các mô hình tính cách	17
3.2.1. Mô hình Chỉ báo Phân loại Myers-Briggs (MBTI)	17
3.2.2. Mô hình tính cách HEXACO	18
3.3. Chuẩn hóa điểm Big Five	19
3.3.1. Thang đo và hướng câu hỏi	19

3.3.2. Ví dụ định dạng dữ liệu đầu vào	19
3.3.3. Vì sao chọn PCA-4 sau khi chuẩn hóa	20
3.4. Đề xuất PCA-4	20
3.5. Huấn luyện PCA	21
3.5.1. Nguồn dữ liệu và quy mô	21
3.5.2. Công thức chiếu PCA	22
3.5.3. So sánh PCA-2, PCA-3, PCA-4	23
3.6. Triển khai PCA trên thiết bị	23
3.6.1. Cách triển khai	23
3.6.2. Định dạng lưu trữ	24
3.7. Thảo luận lựa chọn PCA	24
Chương 4. Bảo mật và mã hoá dữ liệu	25
4.1. Mục tiêu của chương	25
4.2. Tổng quan về cơ chế AES-GCM	25
4.2.1. Nguyên lý cơ bản	25
4.2.2. Đầu vào và đầu ra của AES-GCM	26
4.3. Dữ liệu đầu vào từ góc nhìn người dùng	27
4.3.1. Trải nghiệm nhập liệu và ranh giới dữ liệu nhạy cảm	27
4.3.2. Chuyển đổi trên thiết bị	27
4.4. Mã hóa dữ liệu bằng AES-256-GCM	28
4.4.1. Đề xuất AES-GCM	28
4.4.2. Lý do chọn AES-GCM	28
4.4.3. Lựa chọn thay thế: RSA	28
4.4.4. Lựa chọn thay thế: Bcrypt/Scrypt	29

4.4.5. Lựa chọn thay thế: Homomorphic encryption	30
4.4.6. Lựa chọn thay thế: Differential privacy	31
4.4.7. Vai trò của Edge Function và khóa bí mật	32
4.4.8. Lưu trữ và giới hạn truy cập	34
4.5. Dữ liệu sở thích và mã hóa	35
Chương 5. Hệ gợi ý và cơ chế xếp hạng	37
5.1. Mục tiêu của chương	37
5.2. Vì sao vẫn cần tính cách khi đã có sở thích	37
5.3. Đề xuất thuật toán ELO	38
5.3.1. Vai trò của ELO trong hành vi xã giao	38
5.3.2. Bàn luận về thiết kế ELO	39
5.4. Ngưỡng sử dụng sở thích	39
5.5. Đề xuất mô hình ngữ nghĩa (semantic model)	40
5.5.1. Lựa chọn thay thế: TF-IDF	41
5.5.2. Lựa chọn thay thế: Word2Vec	41
5.6. Công thức xếp hạng tổng hợp	42
5.6.1. Bàn luận về trọng số	43
5.6.2. Ví dụ minh họa xếp hạng	44
5.7. Bảo vệ dữ liệu sở thích và quyền riêng tư	44
Chương 6. Thực nghiệm và Đánh giá	45
6.1. Mục tiêu của chương	45
6.2. Câu hỏi nghiên cứu (Research Questions)	45
6.3. Thiết lập thực nghiệm	46
6.3.1. Môi trường và công cụ	46

6.3.2. Tập dữ liệu	46
6.4. Kết quả và phân tích	47
6.4.1. RQ1: Hiệu quả của mô hình PCA-4 và độ tương đồng cosine .	47
6.4.2. RQ2: Đánh giá hệ thống gợi ý lai	48
6.4.3. RQ3: Phân tích hiệu năng	50
6.4.4. RQ4: Đánh giá hiệu quả bảo vệ quyền riêng tư	51
6.5. Thảo luận và Hạn chế	51
6.5.1. Thảo luận	51
6.5.2. Hạn chế	52
6.6. Kết quả thực nghiệm chi tiết	53
6.6.1. 1. Hiệu năng quy trình tạo tài khoản (Upsert Pipeline)	53
6.6.2. 2. Phân tích kết quả gợi ý và Hiệu quả tối ưu hoá	53
6.6.3. 3. Logic cập nhật ELO thực tế	54
Kết luận và Hướng phát triển	55
6.7. Tóm tắt bài toán và kết quả đạt được	55
6.8. Hạn chế của đề tài	56
6.9. Hướng phát triển trong tương lai	56
Công bố liên quan	58
Tài liệu tham khảo	59
Phụ lục	61
A. Bộ câu hỏi Big Five (Phiên bản Tiếng Anh)	61
B. Mã nguồn một số hàm quan trọng	63
B.1. Mã hóa và Giải mã dữ liệu (score-crypto)	63
B.2. Thuật toán Gợi ý người dùng (recommend-users)	64

B.3.	Cập nhật ELO và Tương tác (match-update)	65
B.4.	Chính sách bảo mật cơ sở dữ liệu (RLS Policies)	66
C.	Mã nguồn kịch bản kiểm thử (Benchmarks)	66
C.1.	Script tạo dữ liệu mẫu và đo hiệu năng Upsert (seedMockProfiles.ts)	66
C.2.	Script kiểm thử kịch bản Viewer (benchmark_scenarios.ts) . .	67
D.	Kỹ thuật tối ưu hóa cơ sở dữ liệu	68

DANH MỤC HÌNH ẢNH

Hình 1.1	Bối cảnh ứng dụng mạng xã hội và nhu cầu kết nối theo tính cách	2
Hình 1.2	Rủi ro khi xử lý dữ liệu tính cách theo mô hình tập trung	3
Hình 1.3	Quy trình chuyển đổi Big Five sang vector PCA-4	6
Hình 1.4	Luồng mã hoá AES-GCM và lưu trữ dữ liệu tính cách	7
Hình 2.1	Quy trình tổng thể của hệ thống Twins	11
Hình 2.2	Sơ đồ trọng số tính điểm gợi ý	14
Hình 2.3	Luồng dữ liệu giữa thiết bị, Edge Function và cơ sở dữ liệu	15
Hình 3.1	Minh họa mô hình MBTI và cách phân nhóm tính cách	18
Hình 3.2	Minh họa cấu trúc 6 yếu tố của HEXACO	19
Hình 3.3	Minh họa tiêu chí lựa chọn PCA-4	21
Hình 3.4	Minh họa phép chiếu PCA và định dạng vector đầu ra	22
Hình 3.5	Đồ thị phương sai giải thích theo số chiều PCA	23
Hình 4.1	Định dạng đầu vào/đầu ra của AES-GCM	26
Hình 4.2	Luồng giao diện và vị trí tổng hợp điểm Big Five	27
Hình 4.3	Ví dụ chi phí tính toán khi dùng RSA cho payload nhỏ	29
Hình 4.4	So sánh dữ liệu băm và dữ liệu có thể giải mã	30
Hình 4.5	Minh họa độ phức tạp của mã hoá đồng hình	31
Hình 4.6	So sánh sự riêng tư biệt lập và mã hoá dữ liệu cá nhân	32
Hình 4.7	Luồng mã hoá/giải mã dữ liệu Big Five qua Edge Function	33
Hình 4.8	Nhật ký Edge Function khi mã hoá và giải mã dữ liệu	34
Hình 4.9	Ví dụ dữ liệu đã mã hoá của Big Five trong bảng profiles	35
Hình 4.10	Luồng mã hoá dữ liệu sở thích và lưu trữ vector nhúng	36
Hình 5.1	Ví dụ ELO phản ánh hành vi xã giao qua chuỗi tương tác	38
Hình 5.2	Luồng tạo vector nhúng sở thích bằng mô hình ngữ nghĩa	40
Hình 5.3	Ví dụ hạn chế của TF-IDF khi so khớp sở thích	41
Hình 5.4	So sánh Word2Vec và mô hình nhúng câu trên cụm sở thích	42
Hình 5.5	Cây quyết định tính điểm gợi ý	43
Hình 6.1	Kết quả điểm tương đồng PCA của cặp <code>similar_a</code> và <code>similar_b</code> .	48
Hình 6.2	So sánh thứ hạng gợi ý giữa các kịch bản khác nhau	49
Hình 6.3	Biểu đồ độ trễ trung bình của các Edge Functions	50

DANH MỤC BẢNG

Bảng 6.1	Hiệu năng quy trình tạo tài khoản	53
Bảng 6.2	So sánh hiệu năng gợi ý trước và sau tối ưu hoá	53
Bảng 6.3	Kết quả xếp hạng thực tế sau khi tối ưu hoá	54

DANH MỤC GIẢI THUẬT

Chương 1

Giới thiệu

1.1. Bối cảnh và vấn đề

1.1.1. Mạng xã hội và nhu cầu kết nối theo tính cách

Twins là một ứng dụng mạng xã hội theo hướng bán khép kín, tập trung vào các cộng đồng nhỏ và chất lượng. Ứng dụng hướng tới việc tìm bạn có tính cách và sở thích tương đồng, lấy cảm hứng từ cơ chế lướt của Tinder và yếu tố kết nối thân mật của Locket. Khác với những nền tảng đại trà, Twins ưu tiên kết nối có chiều sâu thay vì số lượng tương tác. Mục tiêu này dẫn tới việc giảm bớt các tín hiệu bề mặt và tăng trọng số cho các yếu tố phản ánh đặc trưng cá nhân ổn định hơn. Về mặt trải nghiệm, người dùng được dẫn qua một chuỗi câu hỏi ngắn gọn để trích xuất tính cách, sau đó dùng kết quả này như một “dấu vân tính cách” phục vụ gợi ý và phân nhóm.

Các nền tảng mạng xã hội và ứng dụng kết nối hiện nay thường tối ưu cho tốc độ ghép cặp và số lượt tương tác, dựa trên yếu tố vị trí, sở thích bề mặt hoặc mạng bạn bè sẵn có. Cách tiếp cận này tạo ra nhiều kết quả, nhưng chưa chắc dẫn tới sự tương hợp lâu dài. Trong khi đó, các mô hình tính cách như Năm Yếu Tố Lớn (Big Five) được xem là khung tham chiếu ổn định, có khả năng giải thích xu hướng hành vi và mức độ phù hợp giữa các cá nhân [1,2].

Ở góc nhìn của đề tài, nhu cầu kết nối theo tính cách có ý nghĩa vì nó gắn với các đặc trưng ít thay đổi theo thời gian, nên phù hợp cho bài toán gợi ý dài hạn. Lựa chọn này cũng tránh việc phụ thuộc quá nhiều vào dữ liệu tương tác ngắn hạn, vốn dễ bị ảnh hưởng bởi bối cảnh, tâm trạng hoặc hiệu ứng thuật toán. Hình [Hình 1.1](#) minh họa bối cảnh ứng dụng và mục tiêu kết nối theo tính cách.



Hình 1.1 — Bối cảnh ứng dụng mạng xã hội và nhu cầu kết nối theo tính cách

Gợi ý hình: fig_context_social_apps.png

1.1.2. Rủi ro dữ liệu tính cách và yêu cầu bảo vệ

Dữ liệu tính cách có thể được suy diễn từ hành vi số hoặc từ bài trắc nghiệm, và thường được xem là dữ liệu nhạy cảm vì nó liên quan trực tiếp đến xu hướng tâm lý và hành vi của người dùng. Nhiều nghiên cứu chỉ ra rằng đặc điểm tính cách có thể dự đoán từ dữ liệu số và có mức độ ổn định cao [3]. Đồng thời, các đặc điểm này có thể bị khai thác để tác động đến hành vi, ví dụ trong các kịch bản thao túng nội dung hoặc quảng cáo cá nhân hóa quá mức [4]. Việc thu thập và lưu trữ tập trung vì thế cần được xem xét cẩn trọng về quyền riêng tư.

Trong những năm gần đây, nhiều nền tảng lớn liên tục bị cơ quan quản lý chỉ trích và xử phạt vì vi phạm quyền riêng tư. Ví dụ, FTC đã áp mức phạt 5 tỉ USD với Facebook vì các vi phạm về dữ liệu cá nhân [5]. Ở châu Âu, CNIL áp phạt Google vì thiếu minh bạch và không có cơ sở pháp lý đầy đủ cho việc xử lý dữ liệu [6]. Các vụ việc này cho thấy áp lực pháp lý ngày càng tăng đối với những hệ thống thu thập dữ liệu người dùng quy mô lớn. Trong bối cảnh đó,

việc thiết kế một quy trình (pipeline) có cơ chế bảo vệ dữ liệu ngay từ đầu là nhu cầu thực tế, không chỉ là lựa chọn kỹ thuật.

Trong bối cảnh đó, đề tài đặt ra yêu cầu bảo vệ dữ liệu tính cách ở mức tương tự như các loại dữ liệu nhạy cảm khác (tin nhắn, mật khẩu). Thay vì để dữ liệu gốc tồn tại dạng văn bản thuần (plaintext) trên máy chủ, hệ thống cần có cơ chế chuyển đổi và mã hoá để giảm thiểu rủi ro rò rỉ. Hình [Hình 1.2](#) mô tả các rủi ro chính khi xử lý dữ liệu tính cách theo mô hình tập trung.



Hình 1.2 — Rủi ro khi xử lý dữ liệu tính cách theo mô hình tập trung

Gợi ý hình: fig_privacy_risks.png

1.2. Mục tiêu và phạm vi

1.2.1. Mục tiêu chính

Mục tiêu của đề tài là xây dựng một quy trình chuyển đổi và bảo vệ dữ liệu tính cách, trong đó dữ liệu gốc được xử lý trên thiết bị, chuyển sang biểu diễn gọn hơn, và chỉ lưu trữ trên máy chủ dưới dạng mã hoá. Bên cạnh đó, hệ thống vẫn phải giữ khả năng so khớp và gợi ý người dùng một cách hiệu quả.

Các mục tiêu chính gồm:

- Xây dựng cơ chế chuyển đổi điểm Big Five sang không gian đặc trưng nhỏ gọn bằng Phân tích Thành phần chính (Principal Component Analysis - PCA) với 4 chiều (PCA-4).
- Thiết kế cơ chế mã hoá theo Chuẩn mã hóa tiên tiến ở chế độ Galois/Counter (AES-GCM) để bảo vệ dữ liệu tính cách khi lưu trữ.
- Duy trì khả năng so khớp dựa trên độ tương đồng cosine (cosine similarity) để phục vụ quy trình gợi ý.

1.2.2. Phạm vi thực hiện

Đề tài tập trung vào khía cạnh chuyển đổi dữ liệu và bảo mật, không đi sâu vào triển khai giao diện hay tối ưu hóa trải nghiệm người dùng. Phạm vi hệ thống bao gồm:

- Thiết bị người dùng thực hiện chấm điểm Big Five và chuyển đổi PCA-4.
- Một hàm thực thi biên (Edge Function) chịu trách nhiệm mã hoá và giải mã bằng AES-GCM.
- Cơ sở dữ liệu lưu trữ vector PCA và dữ liệu đã mã hoá (ciphertext) thay vì dữ liệu thô.

Ngoài ra, từ các biểu diễn đã chuyển đổi này, hệ thống gợi ý sẽ khai thác thêm các nguồn dữ liệu đã được nhúng vector (embedding) từ sở thích và tương tác, nhằm tạo ra kết quả gợi ý có ý nghĩa thực tế nhưng vẫn giữ được nguyên tắc bảo mật thông tin cá nhân.

1.3. Bài toán và cách tiếp cận

1.3.1. Bài toán chuyển đổi dữ liệu tính cách

Bài toán đặt ra là chuyển đổi vector Big Five 5 chiều thành biểu diễn nhỏ gọn nhưng vẫn giữ được tính phân biệt đủ cao cho việc so khớp. Có nhiều hướng thay thế như dùng mô hình nhúng ngữ nghĩa hoặc học sâu, nhưng các hướng này thường yêu cầu dữ liệu huấn luyện lớn hơn và khó giải thích.

Trong đề tài, PCA được chọn vì Big Five là mô hình tâm lý chuẩn hóa, đã có dữ liệu công khai quy mô lớn và ổn định theo quốc gia [1,2]. PCA cho phép giảm chiều mà vẫn giữ được phần lớn phương sai. Kết quả từ notebook thực nghiệm cho thấy PCA-4 giữ khoảng hơn 90% phương sai của dữ liệu gốc, trong

khi PCA-2 hoặc PCA-3 mất đáng kể thông tin [7]. Hình [Hình 1.3](#) mô tả quy trình chuyển đổi Big Five sang PCA-4.

Một điểm quan trọng là tính cách khác với ngôn ngữ tự nhiên. Đối với ngôn ngữ, việc nhúng văn bản thường dựa trên các mô hình ngữ nghĩa (semantic model) lớn vì nội dung có tính mơ hồ, đa nghĩa và phụ thuộc ngữ cảnh. Trong khi đó, Big Five đã là một mô hình tâm lý chuẩn hóa, có cấu trúc dữ liệu rõ ràng và nguồn dữ liệu đủ lớn. Vì vậy PCA và độ tương đồng cosine phù hợp hơn cho phân tích tính cách, giúp giữ tính diễn giải và ổn định. Các mô hình ngữ nghĩa vẫn được sử dụng cho phần sở thích (hobbies), nơi dữ liệu là văn bản tự do và cần ánh xạ ngữ nghĩa.

Nói cách khác, đề tài không tìm cách “học lại” tính cách bằng mô hình ngôn ngữ, mà tận dụng một hệ đo đã có sẵn trong tâm lý học. PCA chỉ là bước nén và sắp xếp lại thông tin, không thay đổi ý nghĩa gốc của Big Five. Điều này giúp tránh lệch chuẩn khi dùng mô hình học sâu khó giải thích, đồng thời giảm phụ thuộc vào dữ liệu huấn luyện nội bộ. Tính cách vì thế được xử lý như một tín hiệu có cấu trúc, còn ngôn ngữ được xử lý như tín hiệu mở.

Ở cấp độ thu thập, hệ thống sử dụng bộ câu hỏi tính cách lớn hơn, sau đó chọn ngẫu nhiên 25 câu cho mỗi lượt làm bài. Mỗi 5 câu đại diện cho một nhóm đặc điểm (trait), và điểm số được cộng hoặc trừ tùy theo hướng câu hỏi. Mô hình không phụ thuộc nội dung câu hỏi mà chỉ quan tâm đến hướng (key) và trait tương ứng. Cách tiếp cận này giúp duy trì tính nhất quán của thang đo trong khi giảm tải thời gian trả lời cho người dùng.



Hình 1.3 — Quy trình chuyển đổi Big Five sang vector PCA-4

Gợi ý hình: fig_pca_pipeline.png

1.3.2. Bài toán bảo mật dữ liệu

PCA không phải cơ chế bảo mật. Các thành phần PCA có thể bị suy ngược gần đúng nếu biết tham số mô hình. Vì vậy, dữ liệu gốc vẫn cần được mã hoá. Trong số các phương án, AES-256-GCM được chọn vì phù hợp với khối lượng dữ liệu (payload) nhỏ, tốc độ cao và có tính toàn vẹn dữ liệu (integrity) nhờ GCM [8]. So với RSA hoặc Bcrypt, AES-GCM ít tốn tài nguyên hơn cho dữ liệu dạng JSON, và phù hợp với mô hình hàm thực thi biên.

Trong hệ thống, khóa AES chỉ nằm ở phía máy chủ (Edge Function). Thiết bị người dùng không giữ khóa, nhằm tránh nguy cơ bị trích xuất từ ứng dụng và vẫn cho phép khôi phục dữ liệu khi đăng nhập lại trên thiết bị khác. Hình [Hình 1.4](#) mô tả luồng mã hoá và lưu trữ dữ liệu tính cách.



Hình 1.4 — Luồng mã hoá AES-GCM và lưu trữ dữ liệu tính cách

Gợi ý hình: fig_encrypt_flow.png

1.4. Đóng góp chính

1.4.1. Đóng góp về mô hình chuyển đổi

Đề tài xây dựng quy trình chuyển đổi Big Five sang PCA-4 chạy trên thiết bị, đảm bảo giảm kích thước dữ liệu nhưng vẫn giữ phần lớn thông tin. Hệ số PCA được huấn luyện trên tập dữ liệu công khai quy mô lớn, giúp kết quả có tính ổn định và tái lập.

1.4.2. Đóng góp về bảo mật

Đề tài đề xuất cơ chế mã hoá AES-256-GCM qua Edge Function, đảm bảo dữ liệu gốc không lưu dưới dạng văn bản thuần trên cơ sở dữ liệu. Cách tiếp cận này cân bằng giữa khả năng so khớp và yêu cầu bảo mật dữ liệu nhạy cảm.

1.4.3. Đóng góp về tài liệu kỹ thuật và minh chứng

Toàn bộ mã nguồn cốt lõi của ứng dụng, bao gồm quy trình xử lý trên thiết bị, các hàm thực thi biên và cấu trúc cơ sở dữ liệu, được cung cấp đính kèm cùng

báo cáo này. Đây là nguồn tài liệu minh chứng cho quá trình hiện thực, đồng thời phục vụ công tác thẩm định và đối soát kết quả của Hội đồng.

1.5. Cấu trúc của báo cáo

Phần còn lại của báo cáo được trình bày như sau:

- [Chương 2](#): Trình bày quy trình tổng thể của hệ thống Twins, từ thu thập dữ liệu đến gợi ý.
- [Chương 3](#): Phân tích chi tiết PCA-4, dữ liệu huấn luyện và cách chuyển đổi.
- (Dự kiến) Chương 4: Trình bày cơ chế bảo mật và luồng mã hoá/giải mã.
- (Dự kiến) Chương 5: Trình bày hệ gợi ý (PCA, ELO, hobbies) và cách tính trọng số.
- (Dự kiến) Chương 6: Thực nghiệm và đánh giá hệ thống.
- (Dự kiến) Chương 7: Kết luận và hướng phát triển.

Chương 2

Tổng quan quy trình hệ thống

2.1. Mục tiêu của chương

Chương này trình bày quy trình (pipeline) tổng thể của hệ thống Twins, theo thứ tự từ thu thập dữ liệu trên thiết bị, chuyển đổi và bảo mật, đến gợi ý người dùng. Mục tiêu là mô tả rõ các tác nhân tham gia, dữ liệu vào ra ở mỗi bước và cách các điểm số được kết hợp thành một điểm xếp hạng cuối cùng. Các chương sau sẽ đi sâu vào từng thành phần. Trong đó, Chương 4 tập trung vào bảo mật và mã hoá dữ liệu, còn Chương 5 trình bày chi tiết hệ gợi ý và các công thức xếp hạng.

2.2. Các nguồn dữ liệu đầu vào

2.2.1. Bộ câu hỏi Big Five và cách lấy mẫu

Hệ thống sử dụng tập câu hỏi Big Five lớn, được tổng hợp từ các bộ câu hỏi chuẩn như IPIP 50 và các biến thể đã được công bố rộng rãi [9]. Mỗi lượt làm bài chọn ngẫu nhiên 25 câu từ một tập hợp (pool) 150 câu, trong đó mỗi 5 câu đại diện cho một đặc điểm (trait). Mỗi câu hỏi có hướng cộng hoặc trừ vào trait tương ứng, do đó mô hình không phụ thuộc nội dung câu hỏi mà chỉ phụ thuộc vào hướng (key) và trait của câu hỏi.

Cách lấy mẫu này giúp giảm thời gian làm bài, đồng thời vẫn giữ được cấu trúc cân bằng giữa các trait. Trên thực tế, hệ thống chỉ cần biết hai thông tin cho mỗi câu: thuộc tính trait nào và hướng tính điểm (cộng hay trừ). Nội dung câu hỏi được giữ để đảm bảo ngữ cảnh người dùng, nhưng không ảnh hưởng đến mô hình chuyển đổi. Trong Chương 3 sẽ trình bày chi tiết cách tính điểm từ thang Likert và quy trình chuẩn hóa.

2.2.2. Dữ liệu khảo sát công khai cho PCA

Để huấn luyện PCA, đề tài sử dụng tập dữ liệu Big Five công khai với hơn 300 nghìn mẫu từ nhiều quốc gia [7]. Dữ liệu đã được chuẩn hóa về thang 0-1 cho từng trait, phù hợp cho việc ước lượng các thành phần chính. Các kết quả giải thích phương sai sẽ được nêu ở Chương 3. Đây là lợi thế của Big Five: dữ liệu chuẩn hóa, quy mô lớn và đã được sử dụng rộng rãi trong nghiên cứu, nên PCA có thể học được cấu trúc phân bố ổn định.

2.2.3. Dữ liệu sở thích (hobbies)

Sở thích người dùng được nhập dưới dạng văn bản ngắn. Văn bản này không dùng để lưu trữ trực tiếp, mà được chuyển thành vector 384 chiều thông qua mô hình nhúng ngữ nghĩa (semantic embedding) từ Jina. Lý do dùng phương pháp nhúng là để so khớp nội dung sở thích theo ngữ nghĩa thay vì so khớp từ khóa đơn thuần. Cách làm này cho phép các sở thích có nghĩa gần nhau (ví dụ “chạy bộ” và “jogging”) vẫn được đánh giá tương đồng. Chi tiết quy trình nhúng và luồng mã hoá dữ liệu sở thích sẽ được mô tả ở Chương 5.

2.3. Tổng quan quy trình và tác nhân

Hệ thống có ba tác nhân chính: thiết bị người dùng, Edge Function và cơ sở dữ liệu. Hình [Hình 2.1](#) mô tả quy trình tổng thể từ thu thập dữ liệu đến gợi ý.



Hình 2.1 — Quy trình tổng thể của hệ thống Twins

Gợi ý hình: fig_pipeline_overview.png

Các bước chính gồm:

- Thiết bị người dùng trả lời 25 câu hỏi, chấm điểm Big Five và chuẩn hóa về thang 0-1.
- Thiết bị chuyển đổi PCA-4 bằng tham số đã huấn luyện sẵn.
- Thiết bị gửi dữ liệu Big Five gốc tới Edge Function để mã hoá AES-256-GCM.
- Cơ sở dữ liệu lưu trữ pca_dim1..4 và ciphertext (b5_cipher, b5_iv).
- Dữ liệu sở thích được nhúng thành vector 384 chiều, mã hoá, và lưu trữ tương tự.
- Hệ gợi ý lấy vector PCA, ELO và vector sở thích để tính điểm xếp hạng.

2.4. Đề xuất phân mảnh địa lý trong quy trình gợi ý

Khi số lượng người dùng tăng lớn, việc so khớp theo tổ hợp từng cặp sẽ làm chi phí tính toán tăng nhanh. Một hướng giảm tải là phân mảnh địa lý

(geosharding), tức chia người dùng theo vùng địa lý hoặc cụm vị trí, sau đó ưu tiên so khớp trong cùng một phân mảnh (shard). Cách này phổ biến ở các ứng dụng hẹn hò vì nó giảm số lượng cặp cần so sánh và tăng tốc phản hồi.

Trong đề tài, geosharding được xem là bước tối ưu hóa dài hạn, chưa ưu tiên ở giai đoạn thử nghiệm. Khi lượng người dùng đủ lớn và chi phí tính toán trở thành nút thắt, hệ thống đề xuất bổ sung tầng shard theo vùng để giới hạn không gian tìm kiếm. Điều này không thay đổi công thức điểm, nhưng làm giảm khối lượng tính toán cho mỗi lượt gợi ý.

2.5. Mô hình điểm và trọng số trong gợi ý

2.5.1. Điểm tương đồng tính cách (PCA)

Vector PCA-4 được dùng để đo tương đồng giữa hai người dùng bằng cosine similarity. Phương pháp này phù hợp vì đo góc giữa hai vector, ít bị ảnh hưởng bởi độ lớn tuyệt đối và ổn định khi dữ liệu đã chuẩn hóa [10]. Công thức cosine similarity sẽ được trình bày chi tiết ở Chương 5.

2.5.2. ELO từ tương tác like/skip

Hệ thống dùng điểm ELO như một thước đo xã giao, phản ánh mức độ tương tác qua hành vi like và skip. Điểm ELO được cập nhật theo kỳ vọng thắng thua trong mô hình Elo gốc, nhưng được điều chỉnh để phù hợp với ngữ cảnh kết nối xã hội [11]. Trong hệ thống:

- Like: cả hai phía tăng nhẹ.
- Skip: chỉ người chủ động skip bị trừ.

Điểm ELO không phải thước đo hấp dẫn tuyệt đối, mà là tín hiệu phụ để gom nhóm người dùng có mức tương tác tương đồng. ELO trong Twins là hệ số ẩn, được cập nhật sau mỗi lần tương tác và bị giới hạn (clamp) trong khoảng 800 đến 2000. Lưu ý rằng cách cập nhật này tạo xu hướng lạm phát điểm ELO theo thời gian, vì lượt “like” làm cả hai phía tăng điểm. Tuy vậy, mục đích chính không phải cạnh tranh, mà là đảm bảo người dùng có mức xã giao gần nhau được ưu tiên gặp nhau hơn.

Trong công thức gốc, kỳ vọng thắng được tính bởi:

$$E_a = \frac{1}{1 + 10^{\frac{R_b - R_a}{400}}} \quad (2.1)$$

Sau đó cập nhật theo $R_{a'} = R_a + K(S_a - E_a)$. Trong Twins, kết quả like được coi là một tín hiệu hợp tác nên cả hai phía tăng nhẹ, còn skip chỉ trừ phía chủ động. Cụ thể, với $K=12$ và được giới hạn trong $[800, 2000]$:

- Like: $R_{a'} = \text{clamp}(R_a + K(1 - E_a))$, $R_{b'} = \text{clamp}(R_b + K(1 - E_b))$.
- Skip: $R_{a'} = \text{clamp}(R_a + K(0 - E_a))$, $R_{b'} = R_b$.

Bên cạnh đó, hệ gợi ý sử dụng hệ số gần nhau ELO để ưu tiên mức xã giao tương đồng:

$$p = \exp\left(-|\Delta R| \frac{1}{\sigma}\right) \quad (2.2)$$

trong đó $\sigma = 400$.

2.5.3. Embedding sở thích và cosine similarity

Sở thích người dùng được chuyển thành vector 384 chiều thông qua mô hình nhúng ngữ nghĩa. Cosine similarity được dùng để đo độ gần về sở thích, thay vì so khớp từ khóa. Cách làm này cho phép hai người dùng từ khác nhau nhưng có ý nghĩa gần nhau vẫn được đánh giá cao hơn.

2.5.4. Trọng số tổng hợp

Điểm xếp hạng cuối cùng được tính theo trọng số của PCA, ELO và hobbies. Trong phiên bản hiện tại:

- Khi không dùng hobbies:
 - Nếu ELO bật: $\text{score} = 0.8 \text{ PCA} + 0.2 \text{ ELO proximity}$.
 - Nếu ELO tắt: $\text{score} = \text{PCA}$.
- Khi dùng hobbies:
 - Nếu ELO bật: $\text{score} = 0.5 * \text{PCA} + 0.2 * \text{ELO} + 0.3 * \text{Hobbies}$.
 - Nếu ELO tắt: $\text{score} = 0.55 * \text{PCA} + 0.45 * \text{Hobbies}$.

Để minh họa, xét ba người dùng A, B, C khi A đang tìm gợi ý. Giả sử A có PCA tương đồng với B và C gần bằng nhau (ví dụ 0.90), nhưng B có sở thích gần hơn (hobbies 0.85) trong khi C có ELO gần hơn (proximity 1.0 so với 0.7). Trong cấu hình có ELO và hobbies, điểm cuối có thể làm B đứng trước nếu lợi thế sở thích lớn hơn lợi thế ELO. Trường hợp ngược lại, nếu B và C ngang nhau về hobbies, thì C sẽ được ưu tiên do proximity cao hơn. Ví dụ này thể hiện vai trò của từng trọng số trong việc phá vỡ tình huống hòa điểm.

Hình [Hình 2.2](#) minh họa sơ đồ trọng số và các nhánh tính điểm.



Hình 2.2 — Sơ đồ trọng số tính điểm gợi ý

Gợi ý hình: fig_score_weights.png

2.6. Luồng dữ liệu chi tiết theo tác nhân

2.6.1. Thiết bị người dùng

Thiết bị thực hiện các bước sau:

- Thu thập câu trả lời và chấm điểm Big Five.
- Chuẩn hóa và chuyển đổi PCA-4.
- Gửi dữ liệu thô tới Edge Function để mã hoá.
- Gửi văn bản sở thích để tạo vector, rồi lưu ciphertext và vector nhúng.

2.6.2. Edge Function

Edge Function đảm nhận:

- Mã hoá/giải mã Big Five bằng AES-256-GCM.
- Gọi dịch vụ nhúng để sinh vector sở thích.

- Trả về ciphertext, iv và vector nhúng cho thiết bị.

2.6.3. Cơ sở dữ liệu

Cơ sở dữ liệu lưu trữ:

- Vector PCA (pca_dim1..4).
- Ciphertext và iv cho Big Five (b5_cipher, b5_iv).
- Ciphertext cho hobbies và vector nhúng.

Hình [Hình 2.3](#) trình bày luồng dữ liệu theo thứ tự tác nhân.



Hình 2.3 — Luồng dữ liệu giữa thiết bị, Edge Function và cơ sở dữ liệu

Gợi ý hình: fig_dataflow_sequence.png

2.7. Cấu trúc các chương tiếp theo

Để đi sâu vào từng thành phần của quy trình, các chương tiếp theo của báo cáo được cấu trúc như sau, tách biệt rõ ràng các phần hiện thực và thực nghiệm để tăng tính mạch lạc:

- **Chương 3: Chuyển đổi dữ liệu tính cách (PCA-4)**, tập trung vào phân lõi của việc xử lý và biểu diễn dữ liệu tính cách.
- **Chương 4: Bảo mật và mã hoá dữ liệu**, trình bày chi tiết kiến trúc bảo mật, một thành phần quan trọng của hệ thống.
- **Chương 5: Hệ gợi ý và cơ chế xếp hạng**, mô tả logic nghiệp vụ của việc kết hợp các tín hiệu để đưa ra gợi ý cuối cùng.
- **Chương 6: Thực nghiệm và Đánh giá**, dành riêng cho việc kiểm chứng và đánh giá toàn bộ hệ thống dựa trên các câu hỏi nghiên cứu đã đề ra.

Cách phân chia này giúp người đọc theo dõi chi tiết từng khía cạnh của việc “Hiện thực” (Chương 3, 4, 5) trước khi đi vào phần “Thực nghiệm” (Chương 6).

Chương 3

Chuyển đổi dữ liệu tính cách (PCA-4)

3.1. Mục tiêu của chương

Chương này trình bày chi tiết quy trình chuyển đổi dữ liệu Big Five sang vector PCA-4, bao gồm cách chuẩn hóa điểm, cách huấn luyện PCA và cách triển khai trên thiết bị. Mục đích là làm rõ vì sao PCA-4 được chọn thay vì PCA-2/3 hoặc các mô hình nhúng vector khác.

3.2. Big Five trong bối cảnh các mô hình tính cách

Trong tâm lý học có nhiều khung mô tả tính cách, không có mô hình nào tuyệt đối hoàn hảo. Big Five được sử dụng vì đã có lịch sử nghiên cứu dài, hệ thống câu hỏi chuẩn hóa và dữ liệu công khai phong phú. So với các mô hình khác như MBTI hoặc HEXACO, Big Five có ưu thế về tính tái lập và độ phủ dữ liệu, phù hợp cho bài toán chuyển đổi số liệu quy mô lớn [2,12]. Do đó, đề tài chấp nhận giới hạn của mô hình nhưng coi Big Five là lựa chọn thực tế nhất để làm nền cho quy trình chuyển đổi dữ liệu.

3.2.1. Mô hình Chỉ báo Phân loại Myers-Briggs (MBTI)

MBTI phân loại người dùng theo các cặp đối lập, tạo ra 16 nhóm tính cách. Cách biểu diễn này dễ truyền thông nhưng thiên về phân loại rời rạc, trong khi dữ liệu thực tế thường có phân bố liên tục. Với bài toán gợi ý cần đo mức độ gần nhau, dạng nhãn rời rạc làm giảm khả năng xếp hạng chi tiết và khó phản ánh mức độ “gần” giữa hai cá nhân. MBTI cũng có vấn đề về độ ổn định theo thời gian, nhiều người thay đổi nhóm khi làm lại bài test. Điều này làm cho dữ liệu khó tái lập và khó dùng cho quy trình so khớp dài hạn. Ngoài ra, MBTI ít có dữ liệu mở quy mô lớn theo chuẩn hóa số điểm, nên khó dùng cho chuyển đổi

PCA và huấn luyện ổn định. Ví dụ, hai người thuộc nhóm INFP và ENFP có thể khác nhau mạnh về hướng ngoại nhưng vẫn bị xem là hai nhân rời rạc. Hình [Hình 3.1](#) minh họa cách MBTI chia nhóm tính cách.



Hình 3.1 — Minh họa mô hình MBTI và cách phân nhóm tính cách

Gợi ý hình: fig_mbti_overview.png

3.2.2. Mô hình tính cách HEXACO

HEXACO mở rộng Big Five bằng cách thêm yếu tố Trung thực-Khiêm tốn (Honesty-Humility). Mô hình này có giá trị về mặt học thuật, nhưng dữ liệu mở và bộ câu hỏi chuẩn hóa không phổ biến bằng Big Five. Việc thêm một đặc điểm (trait) thứ sáu làm tăng số câu hỏi cần thiết để giữ cân bằng độ tin cậy. Điều này gây áp lực lên trải nghiệm người dùng di động, vì thời gian trả lời dài hơn. Ngoài ra, chuyển đổi từ HEXACO sang dạng PCA sẽ cần dữ liệu huấn luyện riêng, trong khi dữ liệu chuẩn không nhiều bằng Big Five. Ví dụ, nếu chỉ dùng 25 câu, mỗi trait sẽ bị giảm số câu đánh giá, làm tăng nhiễu đo lường. Do đó HEXACO được xem là lựa chọn tham khảo hơn là lựa chọn chính cho đề tài. Hình [Hình 3.2](#) minh họa cấu trúc HEXACO.



Hình 3.2 — Minh họa cấu trúc 6 yếu tố của HEXACO

Gợi ý hình: fig_hexaco_overview.png

3.3. Chuẩn hóa điểm Big Five

3.3.1. Thang đo và hướng câu hỏi

Mỗi câu trả lời được chấm theo thang Likert 1–5. Với câu hỏi hướng dương, điểm giữ nguyên thứ tự 1→5. Với câu hỏi hướng âm, điểm được đảo chiều. Sau đó các điểm trong cùng một trait được cộng lại và chuẩn hóa về thang 0–1. Cách chuẩn hóa này giúp các trait có cùng thang đo, phù hợp cho PCA và so khớp cosine.

3.3.2. Ví dụ định dạng dữ liệu đầu vào

Sau bước chuẩn hóa, mỗi người dùng có một vector 5 chiều theo thứ tự trait cố định:

```
x = [Extraversion, Agreeableness, Conscientiousness, Emotional Stability, Intellect]
```

Ví dụ một người dùng có thể có:

```
x = [0.68, 0.55, 0.72, 0.60, 0.47]
```

Đây là dạng dữ liệu đầu vào cho bước PCA.

3.3.3. Vì sao chọn PCA-4 sau khi chuẩn hóa

Chuẩn hóa đưa dữ liệu Big Five về cùng thang đo, giúp mỗi trait đóng góp cân bằng khi so khớp và khi học PCA. Tuy vậy, chuẩn hóa không giải quyết vấn đề dư thừa thông tin giữa các trait. PCA được dùng để rút gọn chiều và tách các trục phương sai lớn nhất. Trong khi PCA-2 hoặc PCA-3 làm mất đáng kể thông tin, PCA-4 là điểm cân bằng tối ưu: giảm chiều từ 5 xuống 4 nhưng vẫn giữ phần lớn phương sai, giúp hệ gợi ý hoạt động ổn định khi đo độ tương đồng cosine.

3.4. Đề xuất PCA-4

Đề tài đề xuất PCA-4 như mức giảm chiều tối ưu cho Big Five trong bối cảnh gợi ý bạn bè. Giảm từ 5 xuống 4 chiều giúp tiết kiệm lưu trữ mà vẫn giữ phần lớn cấu trúc dữ liệu. PCA-4 cũng là dạng biểu diễn dễ triển khai trên thiết bị với phép nhân ma trận thuần. Mức giảm nhẹ này giúp hạn chế rủi ro mất thông tin so với PCA-2 hoặc PCA-3. Ngoài ra, PCA-4 giữ được tính diễn giải tương đối, phù hợp với việc so sánh độ tương đồng cosine ổn định. Hình [Hình 3.3](#) gợi ý một minh họa quyết định chọn PCA-4 dựa trên phương sai.



Hình 3.3 — Minh họa tiêu chí lựa chọn PCA-4

Gợi ý hình: fig_pca_proposal.png

3.5. Huấn luyện PCA

3.5.1. Nguồn dữ liệu và quy mô

PCA được huấn luyện từ tập dữ liệu Big Five công khai quy mô lớn, sử dụng tệp `big_five_scores.csv` (khoảng 307 nghìn bản ghi) [7,13]. Dữ liệu bao gồm thông tin theo quốc gia và đã chuẩn hóa điểm về thang 0–1. Trong quá trình thăm dò, thống kê cho thấy dữ liệu trải rộng khoảng hơn 200 quốc gia và vùng lãnh thổ, với các phân phối điểm khá ổn định giữa các nhóm quốc gia lớn. Một số bản ghi thiếu nhãn quốc gia, nhưng các cột điểm số vẫn đầy đủ, vì vậy không ảnh hưởng đến việc huấn luyện PCA.

Phân tích Dữ liệu Khám phá (Exploratory Data Analysis - EDA) trong notebook cho thấy chênh lệch trung bình giữa các quốc gia tồn tại nhưng không đủ lớn để cần một mô hình riêng theo vùng. Do đó, PCA được huấn luyện trên toàn bộ tập dữ liệu để nắm bắt phương sai tổng thể. Đây là quyết định thực

tế giúp mô hình ổn định và tái lập, đồng thời tránh việc phải duy trì nhiều mô hình theo vùng.

Đề tài không huấn luyện mô hình học sâu cho tính cách vì mục tiêu chính là biến đổi và nén dữ liệu đã có cấu trúc. PCA cho phép giữ tính giải thích, dễ triển khai trên thiết bị và không cần dữ liệu nhãn bổ sung. Nếu dùng mô hình phức tạp hơn, chi phí huấn luyện và suy diễn sẽ tăng, trong khi lợi ích bổ sung không rõ ràng vì dữ liệu đã được chuẩn hóa.

3.5.2. Công thức chiếu PCA

PCA thực hiện phép chiếu tuyến tính trên dữ liệu đã được trừ đi giá trị trung bình. Với vector đầu vào x (dài 5), ta có:

$$z = (x - \mu) \times W^T \quad (3.3)$$

trong đó μ là vector trung bình (mean) và W là ma trận chứa các thành phần chính (components) [14]. Vector z là PCA-4 và được lưu dưới dạng 4 chiều. Hình [Hình 3.4](#) mô tả phép chiếu và định dạng đầu ra.



Hình 3.4 — Minh họa phép chiếu PCA và định dạng vector đầu ra

Gợi ý hình: fig_pca_math.png

3.5.3. So sánh PCA-2, PCA-3, PCA-4

Trong notebook thực nghiệm, PCA-2 chỉ giữ khoảng 63% phương sai, PCA-3 khoảng 80%, trong khi PCA-4 giữ hơn 90% phương sai dữ liệu gốc. Sự chênh lệch này ảnh hưởng trực tiếp đến khả năng phân biệt giữa các người dùng khi so khớp. Vì vậy PCA-4 được chọn để giảm mất thông tin mà vẫn đảm bảo kích thước nhỏ gọn.

Hình [Hình 3.5](#) minh họa đồ thị phương sai giải thích theo số chiều.



Hình 3.5 — Đồ thị phương sai giải thích theo số chiều PCA

Gợi ý hình: fig_pca_variance.png

3.6. Triển khai PCA trên thiết bị

3.6.1. Cách triển khai

Thay vì chạy mô hình học sâu, PCA-4 được triển khai bằng phép nhân ma trận thuần trên thiết bị. Các hệ số trung bình và thành phần chính được trích từ notebook huấn luyện và lưu cố định trong ứng dụng. Cách này giảm phụ thuộc

vào các thư viện học máy (Machine Learning - ML) và hạn chế kích thước gói ứng dụng (bundle).

3.6.2. Định dạng lưu trữ

Kết quả PCA-4 được lưu dưới dạng 4 trường số: `pca_dim1..pca_dim4`. Các giá trị này được lưu song song với ciphertext của Big Five. Việc lưu PCA dạng số thực giúp tính độ tương đồng cosine trực tiếp ở phía máy chủ khi gọi ý.

3.7. Thảo luận lựa chọn PCA

PCA là phép biến đổi tuyến tính, có thể giải thích và kiểm soát. Các lựa chọn thay thế như nhúng vector học sâu hoặc nhúng ngữ nghĩa (semantic embedding) không phù hợp vì dữ liệu tính cách đã có cấu trúc rõ ràng và ít phụ thuộc ngôn ngữ. Ngoài ra, PCA giúp duy trì tính ổn định giữa các phiên bản, tránh lệch kết quả do thay đổi mô hình.

Chương 4

Bảo mật và mã hoá dữ liệu

4.1. Mục tiêu của chương

Chương này trình bày cách dữ liệu được nhập từ góc độ người dùng, cách dữ liệu được chuyển đổi và mã hoá trước khi lưu trữ, cùng với lý do lựa chọn cơ chế AES-256-GCM. Trọng tâm là luồng dữ liệu và các tác nhân, không đi sâu vào mã nguồn chi tiết.

4.2. Tổng quan về cơ chế AES-GCM

4.2.1. Nguyên lý cơ bản

AES là thuật toán mã hoá đối xứng khối, hoạt động trên các khối dữ liệu cố định và cần một khóa chung cho cả quá trình mã hoá lẫn giải mã. Chế độ GCM (Galois/Counter Mode) kết hợp giữa mã hoá dạng bộ đếm (counter mode) và cơ chế xác thực dữ liệu. Nhờ đó, ngoài dữ liệu đã mã hoá (ciphertext), hệ thống còn có thể kiểm tra tính toàn vẹn (integrity) của dữ liệu [8]. Trong ngữ cảnh dữ liệu tính cách, yếu tố này rất quan trọng để đảm bảo dữ liệu không bị thay đổi trái phép mà không bị phát hiện.

Một phiên làm việc AES-GCM tạo ra thêm thẻ xác thực (authentication tag), giúp phát hiện bất kỳ sự thay đổi nào đối với dữ liệu hoặc vector khởi tạo (Initialization Vector - IV). Nếu thẻ xác thực không khớp, dữ liệu sẽ bị từ chối giải mã. Cơ chế này làm giảm nguy cơ người dùng nhận phải dữ liệu sai lệch hoặc đã bị chỉnh sửa khi truyền qua mạng. Với dữ liệu nhạy cảm như tính cách và sở thích, việc đảm bảo tính toàn vẹn quan trọng không kém việc giữ bí mật. Vì vậy, AES-GCM phù hợp hơn các chế độ chỉ mã hoá mà không đi kèm xác thực.

4.2.2. Đầu vào và đầu ra của AES-GCM

Đầu vào bao gồm dữ liệu gốc (dưới dạng JSON chứa điểm Big Five hoặc danh sách sở thích), khóa bí mật, và một IV ngẫu nhiên. Đầu ra bao gồm dữ liệu đã mã hoá (ciphertext) và IV tương ứng. Trong triển khai của đề tài, IV được lưu trữ riêng trong cơ sở dữ liệu để phục vụ quá trình giải mã sau này. Hình [Hình 4.1](#) mô tả cấu trúc đầu vào và đầu ra của quy trình này.

Việc lưu trữ thẻ xác thực đi kèm ciphertext cho phép hệ thống kiểm tra tính toàn vẹn ngay tại thời điểm giải mã. Nếu phát hiện sai lệch, hệ thống sẽ từ chối giải mã và ghi nhận lỗi, ngăn chặn việc trả về dữ liệu sai. Cách lưu trữ này bảo vệ dữ liệu cá nhân khỏi các thay đổi ngầm ở cấp độ cơ sở dữ liệu hoặc trong quá trình truyền tải.



Hình 4.1 — Định dạng đầu vào/đầu ra của AES-GCM

Gợi ý hình: fig_aes_io.png

4.3. Dữ liệu đầu vào từ góc nhìn người dùng

4.3.1. Trải nghiệm nhập liệu và ranh giới dữ liệu nhạy cảm

Người dùng thực hiện bộ câu hỏi tính cách gồm 25 câu hỏi trong một lượt. Các câu trả lời này được xem là dữ liệu nhạy cảm vì có thể dùng để suy diễn đặc trưng tâm lý. Ngay khi người dùng hoàn tất, hệ thống chỉ lưu lại các điểm số đã được tổng hợp theo mô hình Big Five, không lưu trữ câu trả lời gốc cho từng câu hỏi. Việc này giúp giảm thiểu rủi ro rò rỉ dữ liệu thô và hạn chế khả năng định danh gián tiếp.

Hình [Hình 4.2](#) gợi ý bố trí giao diện và vị trí bước tổng hợp điểm trong luồng ứng dụng.



Hình 4.2 — Luồng giao diện và vị trí tổng hợp điểm Big Five

Gợi ý hình: fig_ui_quiz_flow.png

4.3.2. Chuyển đổi trên thiết bị

Sau khi tổng hợp, điểm Big Five được chuẩn hóa và chuyển đổi sang không gian PCA-4 ngay trên thiết bị người dùng. Kết quả PCA là dữ liệu đã giảm

chiều, đủ cho mục đích so khớp nhưng không thay thế hoàn toàn được dữ liệu thô. Tuy nhiên, vì PCA là phép biến đổi tuyến tính, thông tin gốc vẫn có thể bị suy ngược gần đúng nếu biết tham số mô hình. Do đó, dữ liệu gốc vẫn cần được mã hoá trước khi lưu trữ.

4.4. Mã hóa dữ liệu bằng AES-256-GCM

4.4.1. Đề xuất AES-GCM

Đề tài đề xuất sử dụng AES-256-GCM làm cơ chế mã hoá chính cho dữ liệu tính cách và sở thích. Lý do là dữ liệu có kích thước nhỏ, yêu cầu tốc độ xử lý nhanh và cần khả năng giải mã để hiển thị lại trên giao diện người dùng. AES-GCM đáp ứng tốt ba yêu cầu: tốc độ, xác thực và dễ dàng triển khai trên các hàm thực thi biên (Edge Function). Cơ chế này cũng cho phép lưu trữ IV riêng biệt để tái tạo dữ liệu khi người dùng đăng nhập lại. Trong phạm vi khóa luận, AES-GCM là lựa chọn tối ưu để cân bằng giữa bảo mật và khả năng vận hành thực tế.

4.4.2. Lý do chọn AES-GCM

AES-GCM được lựa chọn vì phù hợp với các gói dữ liệu (payload) nhỏ, tốc độ cao, và tích hợp sẵn cơ chế xác thực dữ liệu (integrity) cùng lúc với mã hoá [8]. So với RSA hoặc Bcrypt, AES-GCM tiêu tốn ít tài nguyên hơn khi mã hoá các chuỗi JSON ngắn, và dễ dàng tích hợp trong môi trường Edge Function.

4.4.3. Lựa chọn thay thế: RSA

RSA là thuật toán mã hoá bất đối xứng, thường dùng để trao đổi khóa hoặc ký số [15]. Trong bối cảnh dữ liệu tính cách, RSA không phù hợp để mã hoá trực tiếp dữ liệu vì chi phí tính toán lớn và giới hạn về kích thước dữ liệu đầu vào. Nếu sử dụng RSA cho mỗi lần cập nhật hồ sơ, hệ thống sẽ gặp vấn đề về độ trễ và khó mở rộng trên thiết bị di động. Ngoài ra, RSA thường đi kèm các cơ chế đệm (padding) phức tạp, dễ phát sinh lỗi nếu không được triển khai cẩn trọng. Vì vậy, RSA được xem là phương án thay thế nhưng không phù hợp làm cơ chế mã hoá chính cho dữ liệu người dùng. Ví dụ, việc mã hoá một gói tin JSON nhỏ bằng RSA đòi hỏi nhiều bước xử lý đệm và tách khối, gây chậm trễ đáng kể khi người dùng cập nhật hồ sơ liên tục.



Hình 4.3 — Ví dụ chi phí tính toán khi dùng RSA cho payload nhỏ

Gợi ý hình: fig_rsa_alt.png Gợi ý hình: fig_rsa_alt.png

4.4.4. Lựa chọn thay thế: Bcrypt/Scrypt

Bcrypt và Scrypt là các hàm băm mật khẩu (password hashing function) [16]. Ưu điểm của chúng là làm chậm các cuộc tấn công dò khóa (brute-force), nhưng nhược điểm là dữ liệu sau khi băm không thể giải mã để lấy lại nội dung gốc. Trong hệ thống Twins, người dùng cần xem lại kết quả tính cách và sở thích của mình, do đó yêu cầu bắt buộc là phải giải mã được dữ liệu. Nếu dùng bcrypt, hệ thống chỉ có thể so khớp chuỗi băm mà không thể trả lại dữ liệu gốc cho giao diện. Điều này đi ngược lại yêu cầu về trải nghiệm người dùng và giới hạn chức năng của ứng dụng. Vì vậy, các hàm băm này không phù hợp. Ví dụ, sở thích “chạy bộ” sau khi băm sẽ trở thành một chuỗi ký tự ngẫu nhiên và không thể khôi phục để hiển thị lại là “chạy bộ”.



Hình 4.4 — So sánh dữ liệu băm và dữ liệu có thể giải mã

Gợi ý hình: fig_bcrypt_alt.png Gợi ý hình: fig_bcrypt_alt.png

4.4.5. Lựa chọn thay thế: Homomorphic encryption

Mã hoá đồng hình (Homomorphic encryption) cho phép thực hiện tính toán trực tiếp trên dữ liệu đã mã hoá mà không cần giải mã [17]. Đây là hướng đi rất mạnh về bảo mật, nhưng chi phí tính toán cực kỳ cao và việc triển khai rất phức tạp. Với bài toán gợi ý cần phản hồi nhanh, việc áp dụng mã hoá đồng hình sẽ làm tăng độ trễ hệ thống và đòi hỏi hạ tầng phần cứng đặc biệt. Ngoài ra, mô hình này chưa thực sự cần thiết vì đề tài không yêu cầu tính toán phức tạp trực tiếp trên dữ liệu mã hoá mà chỉ cần lưu trữ an toàn và giải mã khi cần thiết. Do đó, mã hoá đồng hình vượt quá phạm vi thực tế của khóa luận. Ví dụ, một phép so khớp cosine trên dữ liệu mã hoá đồng hình có thể chậm hơn nhiều lần so với trên dữ liệu văn bản thuần, gây trải nghiệm kém mượt mà trên thiết bị di động.



Hình 4.5 — Minh họa độ phức tạp của mã hoá đồng hình

Gợi ý hình: fig_homomorphic_alt.png Gợi ý hình: fig_homomorphic_alt.png

4.4.6. Lựa chọn thay thế: Differential privacy

Sự riêng tư biệt lập (Differential privacy) tập trung vào việc ẩn danh hóa khi công bố các số liệu thống kê [18]. Phương pháp này phù hợp cho dữ liệu tổng hợp, nhưng không giải quyết được bài toán lưu trữ và giải mã dữ liệu cho từng cá nhân cụ thể. Nếu chỉ áp dụng sự riêng tư biệt lập, người dùng vẫn cần truy cập vào dữ liệu gốc của chính mình, dẫn tới vấn đề bảo mật vẫn tồn tại ở cấp độ lưu trữ. Trong hệ thống Twins, yêu cầu là bảo vệ dữ liệu của từng người nhưng vẫn cho phép họ xem lại nội dung đó. Vì vậy, sự riêng tư biệt lập được coi như một kỹ thuật bổ trợ chứ không thể thay thế cho AES-GCM. Ví dụ, nếu cộng thêm nhiễu vào điểm Big Five để bảo vệ tính ẩn danh trong thống kê, kết quả gợi ý cá nhân hóa cho người dùng sẽ bị giảm độ chính xác và khó giải thích.



Hình 4.6 — So sánh sự riêng tư biệt lập và mã hoá dữ liệu cá nhân

Gợi ý hình: fig_dp_alt.png Gợi ý hình: fig_dp_alt.png

4.4.7. Vai trò của Edge Function và khóa bí mật

Khóa AES chỉ tồn tại ở phía Edge Function (máy chủ biên). Thiết bị người dùng không lưu trữ khóa này, nhằm tránh nguy cơ bị trích xuất từ ứng dụng. Đồng thời, cách thiết kế này cho phép người dùng phục hồi dữ liệu khi đăng nhập lại trên một thiết bị khác. Đây là sự cân bằng hợp lý giữa bảo mật và khả năng khôi phục dữ liệu.

Hình [Hình 4.7](#) mô tả luồng dữ liệu trong quá trình mã hoá và giải mã.



Hình 4.7 — Luồng mã hoá/giải mã dữ liệu Big Five qua Edge Function

Gợi ý hình: fig_crypto_flow.png

Hình [Hình 4.8](#) minh họa nhật ký (log) của Edge Function cho quá trình mã hoá và giải mã.



Hình 4.8 — Nhật ký Edge Function khi mã hoá và giải mã dữ liệu

Gợi ý hình: `fig_edge_logs.png`

4.4.8. Lưu trữ và giới hạn truy cập

Cơ sở dữ liệu chỉ lưu trữ dữ liệu đã mã hoá và IV cho Big Five (các trường `b5_cipher`, `b5_iv`). Điều này có nghĩa là quản trị viên cơ sở dữ liệu không thể đọc trực tiếp dữ liệu tính cách dưới dạng văn bản thuần. Dữ liệu chỉ được giải mã khi người dùng đã xác thực thành công và gửi yêu cầu thông qua Edge Function. Cách làm này hạn chế nguy cơ giám sát hàng loạt (mass surveillance) từ bảng dữ liệu chưa mã hoá, đồng thời vẫn đảm bảo tính năng xem lại kết quả cho người dùng.

Hình [Hình 4.9](#) minh họa mẫu dữ liệu đã mã hoá được lưu trong cơ sở dữ liệu.



Hình 4.9 — Ví dụ dữ liệu đã mã hoá của Big Five trong bảng profiles

Gợi ý hình: `fig_cipher_sample.png`

4.5. Dữ liệu sở thích và mã hóa

Sở thích người dùng được nhập dưới dạng văn bản tự do, sau đó được nhúng thành vector 384 chiều. Dữ liệu văn bản này cũng được mã hoá theo cơ chế AES-GCM tương tự như Big Five. Do đó, giao diện ứng dụng có thể hiển thị lại sở thích sau khi giải mã, nhưng cơ sở dữ liệu hoàn toàn không lưu trữ văn bản thuần.

Hình [Hình 4.10](#) mô tả luồng dữ liệu sở thích từ nhập liệu đến lưu trữ.



Hình 4.10 — Luồng mã hoá dữ liệu sở thích và lưu trữ vector nhúng

Gợi ý hình: fig_hobby_encrypt.png

Chương 5

Hệ gợi ý và cơ chế xếp hạng

5.1. Mục tiêu của chương

Chương này mô tả cách hệ gợi ý kết hợp ba nguồn tín hiệu: tính cách (PCA), hành vi xã giao (ELO) và sở thích được nhúng vector (embedding hobbies). Đồng thời, chương giải thích vì sao từng tín hiệu vẫn cần thiết, ngay cả khi người dùng đã khai báo sở thích, và đi sâu vào các luận điểm thiết kế đằng sau mỗi thành phần.

5.2. Vì sao vẫn cần tính cách khi đã có sở thích

Sở thích (interests) phản ánh các chủ đề người dùng quan tâm, nhưng không đủ để mô tả mức độ tương hợp về cách suy nghĩ và hành vi. Hai người cùng thích “chụp ảnh” có thể khác nhau rõ rệt về cách giao tiếp, nhịp sống và mức độ ổn định cảm xúc. Với các kết nối dài hạn, các khác biệt này thường quan trọng hơn sở thích bề mặt. Hơn nữa, sở thích có thể mang tính thời điểm hoặc thay đổi theo xu hướng, trong khi các đặc điểm tính cách cốt lõi theo mô hình Big Five có xu hướng ổn định hơn nhiều trong suốt cuộc đời của một người trưởng thành.

Vì vậy, tính cách được xác định là **trục ổn định** (stable axis) của hệ gợi ý, đảm bảo các kết nối có nền tảng vững chắc và chiều sâu. Sở thích đóng vai trò **trục ngữ cảnh** (contextual axis), giúp bổ trợ, phá vỡ các trường hợp hòa điểm và tìm ra các điểm chung tức thời. Việc kết hợp cả hai giúp hệ thống vừa ổn định trong dài hạn, vừa linh hoạt trong ngắn hạn.

5.3. Đề xuất thuật toán ELO

Trong hệ thống, ELO được dùng như một tín hiệu hành vi ẩn. ELO không nói người dùng “tốt” hơn hay “xấu” hơn, mà phản ánh mức độ xã giao thể hiện qua lượt like/skip. Công thức cập nhật dựa trên kỳ vọng thắng thua gốc của Elo [11], được điều chỉnh để phù hợp với bối cảnh kết nối, nơi lượt like là một tín hiệu hợp tác. Cách cập nhật chi tiết đã được mô tả ở (2.1) và (2.2). Việc giới hạn điểm trong khoảng 800–2000 giúp tránh việc điểm bị trôi quá xa và làm giảm tác dụng phân nhóm hành vi.

Hình [Hình 5.1](#) minh họa trực quan cách ELO phản ánh hành vi xã giao qua các chuỗi like/skip khác nhau.



Hình 5.1 — Ví dụ ELO phản ánh hành vi xã giao qua chuỗi tương tác

Gợi ý hình: fig_elo_behavior.png

5.3.1. Vai trò của ELO trong hành vi xã giao

Điểm ELO phản ánh mức độ like/skip trong thực tế. Đây là tín hiệu hành vi, không phải kết quả tự khai báo. Nó đóng vai trò là một cơ chế hiệu chỉnh, giúp giảm sai lệch giữa những gì người dùng **nói** họ là (qua bài trắc nghiệm) và

những gì họ **làm** (qua hành vi lướt). Khi người dùng thường xuyên skip, điểm ELO giảm và hệ thống ưu tiên gợi ý những người có mức xã giao tương đồng.

ELO trong hệ thống là hệ số ẩn, được cập nhật sau mỗi tương tác và giới hạn trong khoảng 800–2000. Mặc dù cập nhật theo kiểu hợp tác dẫn tới lạm phát điểm, mục tiêu chính là gom nhóm hành vi thay vì xếp hạng cạnh tranh.

5.3.2. Bàn luận về thiết kế ELO

Việc điều chỉnh thuật toán ELO cho bối cảnh mạng xã hội thay vì một trò chơi đối kháng tổng bằng không (zero-sum game) là một quyết định thiết kế quan trọng.

- **Quy tắc cập nhật “hợp tác”:** Trong cờ vua, một người thắng thì người kia thua. Trong một tương tác “like”, cả hai đều có thể nhận được giá trị. Việc tăng điểm cho cả hai bên khuyến khích tương tác tích cực và tránh “trừng phạt” người được yêu thích. Ngược lại, chỉ người chủ động “skip” bị trừ điểm, vì đây là hành động đơn phương thể hiện sự không phù hợp từ phía họ.
- **Hệ số K (K-factor):** Hệ số $K=12$ được chọn là một giá trị tương đối nhỏ. Điều này làm cho điểm ELO thay đổi từ từ, phản ánh một quá trình xây dựng “danh tiếng xã giao” dài hạn thay vì biến động mạnh sau vài tương tác. Nó giúp điểm số ổn định hơn và tránh bị lạm dụng.
- **Cơ chế Giới hạn (Clamping) (800-2000):** Việc giới hạn điểm số trong một khoảng nhất định ngăn chặn hiện tượng “lạm phát ELO” vô hạn và giữ cho sự khác biệt về điểm số luôn nằm trong một phạm vi có ý nghĩa, đảm bảo thành phần ELO proximity trong công thức tổng hợp không trở nên quá lớn hoặc quá nhỏ.

5.4. Ngưỡng sử dụng sở thích

Sở thích chỉ được dùng khi người dùng nhập đủ số lượng tối thiểu (3 mục). Điều này tránh việc dùng dữ liệu quá ít dẫn tới nhiễu hoặc thiên lệch do một sở thích đơn lẻ. Khi đủ ngưỡng, vector nhúng (embedding vector) được tạo và dùng độ tương đồng cosine để tính điểm gần nhau về sở thích. Quy tắc ngưỡng này cũng giúp người dùng mới không bị bất lợi nếu chưa kịp khai báo đầy đủ sở thích, tạo ra một sân chơi công bằng hơn.

5.5. Đề xuất mô hình ngữ nghĩa (semantic model)

Đề tài sử dụng mô hình ngữ nghĩa của Jina (semantic model) để chuyển đổi văn bản sở thích thành vector 384 chiều. Lý do chính là khả năng nắm bắt tương đồng ngữ nghĩa thay vì trùng từ khóa, phù hợp với cách người dùng mô tả sở thích bằng nhiều cách khác nhau. Mô hình kiểu nhúng câu (sentence embedding) cũng ổn định khi so khớp độ tương đồng cosine, dễ triển khai và ít tốn tài nguyên hơn so với các mô hình sinh lớn [19]. Hình [Hình 5.2](#) mô tả luồng chuyển đổi từ văn bản sang vector và cách dùng độ tương đồng cosine trong gợi ý.

Trong triển khai hiện tại, hệ thống ghép sở thích thành một chuỗi ngắn theo mẫu `interests: ...` rồi sinh một vector duy nhất. Cách làm này là một sự đánh đổi có chủ đích giữa độ chính xác và hiệu năng. Việc chỉ có một vector cho mỗi người dùng giúp giảm chi phí so sánh xuống $O(N)$, thay vì $O(N*k^2)$ nếu mỗi người có k sở thích và phải so sánh chéo. Điều này giúp hệ thống có khả năng mở rộng tốt hơn. Quan điểm của đề tài là ưu tiên tính ổn định và khả năng mở rộng, và chỉ xem xét mô hình đa vector khi có hạ tầng đủ mạnh.



Hình 5.2 — Luồng tạo vector nhúng sở thích bằng mô hình ngữ nghĩa

Gợi ý hình: fig_semantic_model.png

5.5.1. Lựa chọn thay thế: TF-IDF

TF-IDF là cách biểu diễn văn bản theo trọng số từ khóa [10]. Điểm mạnh của TF-IDF là đơn giản, dễ giải thích, và chạy nhanh trên thiết bị. Tuy nhiên, TF-IDF không hiểu ngữ nghĩa nên khó nhận biết các từ đồng nghĩa như “jogging” và “chạy bộ”. Ngoài ra, TF-IDF tạo vector thưa và kích thước lớn, làm tăng chi phí lưu trữ và so khớp khi số lượng từ vựng tăng. Trong bối cảnh sở thích ngắn và đa dạng, TF-IDF dễ bị nhiễu bởi các từ hiếm. Vì vậy, TF-IDF được coi là lựa chọn thay thế tham khảo chứ không phù hợp làm lõi gợi ý.



Hình 5.3 — Ví dụ hạn chế của TF-IDF khi so khớp sở thích

Gợi ý hình: fig_tfidf_alt.png

5.5.2. Lựa chọn thay thế: Word2Vec

Word2Vec tạo vector cho từng từ dựa trên ngữ cảnh [20]. Cách này nắm bắt được một phần quan hệ ngữ nghĩa, nhưng vẫn gặp khó khi chuyển sang mức câu hoặc cụm sở thích ngắn. Người dùng thường nhập cụm như “đi phượt cuối tuần” hoặc “nấu ăn healthy”, trong khi Word2Vec cần thêm bước gộp nhiều vector (ví dụ: lấy trung bình) để đại diện cho cả cụm. Việc gộp thủ công làm mất sắc thái

và không ổn định giữa các mẫu khác nhau. Do đó, các mô hình nhúng câu được ưu tiên vì xử lý trực tiếp cụm sở thích, ổn định hơn trong so khớp.



Hình 5.4 — So sánh Word2Vec và mô hình nhúng câu trên cụm sở thích

Gợi ý hình: fig_word2vec_alt.png

5.6. Công thức xếp hạng tổng hợp

Hệ thống tính điểm theo các trọng số đã nêu ở Chương 2. Về bản chất, PCA là trực chính, ELO là trực hành vi, và hobbies là trực ngữ nghĩa. Hình [Hình 5.5](#) mô tả cây quyết định tính điểm và cách nhánh ELO/hobbies được bật tắt.

Việc đặt PCA làm trực chính giúp kết quả ổn định hơn theo thời gian, vì tính cách thay đổi chậm và ít bị ảnh hưởng bởi các biến động ngắn hạn. ELO chỉ đóng vai trò điều chỉnh, tránh trường hợp hai người có tính cách gần nhau nhưng hành vi xã giao quá khác biệt. Hobbies được dùng như một tín hiệu làm mượt, giúp hệ gợi ý nhận ra các chủ đề tương đồng mà tính cách không nắm bắt được. Cấu trúc này giảm rủi ro hệ thống chỉ dựa vào một nguồn dữ liệu duy nhất, vốn dễ gây thiên lệch hoặc thiếu đa dạng.



Hình 5.5 — Cây quyết định tính điểm gợi ý

Gợi ý hình: fig_rank_flow.png

5.6.1. Bàn luận về trọng số

Các trọng số trong công thức tổng hợp (ví dụ: 60% PCA, 15% ELO, 25% Hobbies) được lựa chọn dựa trên các nguyên tắc sau:

- **Tính cách là cốt lõi:** PCA luôn chiếm trọng số cao nhất (trên 50%) để đảm bảo sự tương hợp về tính cách là yếu tố quyết định.
- **Hành vi là yếu tố điều chỉnh:** ELO có trọng số thấp nhất, vì nó chỉ đóng vai trò là một bộ lọc hành vi, tránh các gợi ý “lệch pha” về mức độ tương tác, chứ không phải là yếu tố đo lường sự tương hợp.
- **Sở thích là cầu nối:** Sở thích có trọng số đáng kể nhưng thấp hơn PCA, đóng vai trò là chất xúc tác, tạo ra những điểm chung cụ thể để bắt đầu một mối quan hệ.

Các trọng số này có thể được hiệu chỉnh trong tương lai thông qua các thử nghiệm A/B testing hoặc thậm chí được cá nhân hóa cho từng người dùng, nhưng bộ trọng số hiện tại được xem là một điểm khởi đầu cân bằng và hợp lý.

5.6.2. Ví dụ minh họa xếp hạng

Xét người dùng A đang xem gợi ý, với ba ứng viên B và C. Giả sử:

- PCA similarity: $A-B = 0.90$, $A-C = 0.90$ (hòa nhau).
- Hobbies similarity: $A-B = 0.85$, $A-C = 0.55$.
- ELO proximity: $A-B = 0.70$, $A-C = 1.00$.

Trong cấu hình bất cả ELO và hobbies, điểm cuối của B sẽ tăng nhờ hobbies, còn C tăng nhờ ELO. Nếu trọng số hobbies lớn hơn phần chênh lệch ELO, B sẽ đứng trước. Nếu ngược lại, C sẽ đứng trước. Ví dụ này cho thấy các nguồn tín hiệu có thể phá vỡ thế hòa PCA theo các hướng khác nhau.

5.7. Bảo vệ dữ liệu sở thích và quyền riêng tư

Mặc dù UI có thể hiển thị sở thích đã giải mã, cơ sở dữ liệu không lưu văn bản thuần (plaintext). Điều này tránh việc quản trị viên có thể quét hàng loạt sở thích từ bảng dữ liệu. Người dùng chỉ thấy sở thích khi đã được xác thực và giải mã thông qua Edge Function.

Ngoài ra, việc lưu ciphertext giúp giảm rủi ro lộ dữ liệu ở cấp độ hệ quản trị. Người dùng vẫn nhìn thấy sở thích trên UI vì dữ liệu được giải mã theo phiên đăng nhập hợp lệ, nhưng cơ sở dữ liệu không có điểm tập trung văn bản thuần để khai thác hàng loạt. Đây là điểm khác biệt quan trọng so với cách lưu trữ sở thích truyền thống trong nhiều ứng dụng mạng xã hội.

Chương 6

Thực nghiệm và Đánh giá

6.1. Mục tiêu của chương

Chương này trình bày các thực nghiệm được tiến hành để đánh giá hiệu quả và hiệu năng của hệ thống gợi ý Twins. Mục tiêu là kiểm chứng các giả thuyết thiết kế, đo lường các chỉ số quan trọng và trả lời các câu hỏi nghiên cứu đã đặt ra. Các thực nghiệm tập trung vào ba khía cạnh chính: chất lượng gợi ý, hiệu năng hệ thống và tính hiệu quả của các cơ chế bảo vệ quyền riêng tư.

6.2. Câu hỏi nghiên cứu (Research Questions)

Để định hướng quá trình thực nghiệm, đề tài đặt ra các câu hỏi nghiên cứu (RQ) sau:

- **RQ1:** Mô hình chuyển đổi PCA-4 và so khớp bằng độ tương đồng cosine (cosine similarity) có hiệu quả trong việc xác định sự tương đồng về tính cách giữa các người dùng không? Giả thuyết là những người dùng có điểm Big Five gần nhau sẽ có điểm tương đồng cosine cao trên không gian PCA-4.
- **RQ2:** Hệ thống gợi ý lai (hybrid) kết hợp PCA, ELO và sở thích có mang lại kết quả xếp hạng phù hợp hơn so với việc chỉ sử dụng PCA không? Giả thuyết là việc bổ sung tín hiệu hành vi (ELO) và ngữ nghĩa (sở thích) sẽ giúp phá vỡ các trường hợp hòa điểm và tinh chỉnh thứ hạng gợi ý một cách có ý nghĩa.
- **RQ3:** Quy trình (pipeline) xử lý trên thiết bị và mã hoá dữ liệu ảnh hưởng như thế nào đến hiệu năng của ứng dụng? Câu hỏi này xem xét độ trễ (latency) của các tác vụ tính toán trên thiết bị (PCA) và các lệnh gọi hàm mã hoá/giải mã, cũng như thời gian phản hồi của hệ thống gợi ý.

- **RQ4: Kiến trúc hệ thống có thực sự bảo vệ được quyền riêng tư của người dùng theo thiết kế không?** Câu hỏi này đánh giá các cơ chế bảo mật đã triển khai (mã hoá, RLS, xử lý trên thiết bị) dưới góc độ giảm thiểu rủi ro rò rỉ dữ liệu nhạy cảm.

6.3. Thiết lập thực nghiệm

6.3.1. Môi trường và công cụ

- **Ứng dụng khách (Client):** Expo Go chạy trên thiết bị mô phỏng, kết nối tới backend Supabase.
- **Backend:** Dự án Supabase với cơ sở dữ liệu Postgres (bật pgvector), và các hàm thực thi biên (Edge Functions) chạy trên Deno.
- **Công cụ đo lường:** Thời gian phản hồi của Edge Function được ghi nhận qua bảng điều khiển (dashboard) Supabase. Độ trễ trên thiết bị khách được đo bằng các hàm `console.time` và `console.timeEnd` trong mã nguồn.
- **Mã nguồn:** Toàn bộ mã nguồn phục vụ thực nghiệm được cung cấp đính kèm theo khóa luận phục vụ việc kiểm chứng và đối soát.

6.3.2. Tập dữ liệu

Thực nghiệm sử dụng hai tập người dùng chính:

1. **Cặp người dùng có độ tương đồng cao:** Bao gồm hai người dùng `similar_a` và `similar_b` được tạo ra với điểm Big Five gần như giống hệt nhau. Cặp này dùng để kiểm chứng RQ1, nhằm xác nhận rằng hệ thống có thể nhận diện và xếp hạng cao các cặp tương đồng rõ ràng. Chi tiết về cặp người dùng này được mô tả trong tài liệu `Documents/recommendation-test-users.md`.
2. **Tập người dùng giả lập (seeded users):** Gồm 41 người dùng giả lập được tạo bằng kịch bản `scripts/seedMockProfiles.js`. Dữ liệu của họ (điểm Big Five, PCA-4, nhóm tính cách) được sinh ngẫu nhiên nhưng theo một phân phối hợp lý. Tập dữ liệu này được sử dụng để kiểm tra hệ thống gợi ý ở quy mô nhỏ và đánh giá sự phân bố của các điểm tương đồng.

6.4. Kết quả và phân tích

6.4.1. RQ1: Hiệu quả của mô hình PCA-4 và độ tương đồng cosine

Để trả lời câu hỏi này, truy vấn độ tương đồng cosine được thực hiện trực tiếp trên cơ sở dữ liệu đối với cặp người dùng `similar_a` và `similar_b`.

```
1 with pair as (
2   select id, username, hobby_embedding,
3         vector(array[pca_dim1, pca_dim2, pca_dim3, pca_dim4]) as
         pca_vector
4   from public.profiles
5   where username in ('similar_a', 'similar_b')
6 )
7 select
8   a.username as user_a,
9   b.username as user_b,
10  1 - (a.pca_vector <=> b.pca_vector) as pca_similarity
11 from pair a
12 join pair b on a.id <> b.id;
```

Chương trình 6.1 — Truy vấn SQL để tính toán độ tương đồng cosine cho cặp người dùng `similar_a` và `similar_b`

Kết quả trả về cho thấy điểm `pca_similarity` giữa `similar_a` và `similar_b` là xấp xỉ **0.999**.



Hình 6.1 — Kết quả điểm tương đồng PCA của cặp `similar_a` và `similar_b`

Gợi ý hình: fig_rq1_result.png - Chụp màn hình kết quả của câu lệnh SQL trên

Phân tích: Kết quả này xác nhận giả thuyết của RQ1. Điểm tương đồng rất cao (gần 1.0) chứng tỏ rằng phép biến đổi PCA-4 đã bảo toàn được mối quan hệ tương đồng từ dữ liệu Big Five gốc. Khi đăng nhập bằng tài khoản `similar_a` và tìm kiếm, `similar_b` luôn xuất hiện ở vị trí hàng đầu trong danh sách gợi ý (khi các yếu tố khác như ELO và sở thích được giữ ở mức tương đương). Điều này cho thấy lỗi của hệ thống gợi ý hoạt động đúng như mong đợi.

6.4.2. RQ2: Đánh giá hệ thống gợi ý lại

Để đánh giá tác động của ELO và sở thích, thứ hạng gợi ý cho người dùng `similar_a` được so sánh trong ba kịch bản: (1) chỉ dùng PCA, (2) PCA + ELO, và (3) PCA + ELO + Hobbies.

- **Kịch bản 1 (Chỉ PCA):** `similar_b` đứng đầu. Các vị trí tiếp theo được xếp hạng dựa trên độ tương đồng PCA.
- **Kịch bản 2 (PCA + ELO):** Giả sử một người dùng khác, `user_C`, có điểm PCA thấp hơn `similar_b` một chút nhưng có điểm ELO gần với

`similar_a` hơn. Khi trọng số ELO được thêm vào, `user_C` có thể vượt lên trên một số người dùng có PCA cao hơn nhưng ELO xa hơn.

- **Kịch bản 3 (PCA + ELO + Hobbies):** Bổ sung thêm sở thích. Giả sử `similar_a` có sở thích là “Hiking, Sci-Fi, Cooking”. Một người dùng `user_D` có PCA không quá cao nhưng lại chia sẻ sở thích “Hiking” và “Sci-Fi” sẽ nhận được một điểm cộng đáng kể từ `hobby_similarity`, giúp cải thiện vị trí trong bảng xếp hạng cuối cùng.



Hình 6.2 — So sánh thứ hạng gợi ý giữa các kịch bản khác nhau

Gợi ý hình: fig_rq2_comparison.png - Một bảng so sánh thứ hạng của 3-4 người dùng trong 3 kịch bản trên

Phân tích: Việc thêm ELO và sở thích giúp hệ thống trở nên linh hoạt hơn. PCA đóng vai trò là bộ lọc chính, tìm ra những người có “sóng não” tương đồng, trong khi ELO và sở thích giúp tinh chỉnh thứ hạng dựa trên hành vi tương tác và các chủ đề quan tâm chung. Điều này giúp giải quyết vấn đề người dùng có thể không thấy một người phù hợp dù tính cách tương đồng, do hành vi xã giao hoặc sở thích quá khác biệt. Do đó, hệ thống lai được đánh giá là cung cấp kết quả phù hợp và đa dạng hơn.

6.4.3. RQ3: Phân tích hiệu năng

Độ trễ được đo lường ở hai thành phần chính:

1. **Tính toán PCA trên thiết bị:** Phép tính PCA-4 trên thiết bị khách chỉ là một phép nhân ma trận (5D \rightarrow 4D). Sử dụng `console.time`, thời gian thực thi trung bình trên một thiết bị mô phỏng là **dưới 5 mili giây**. Mức độ trễ này là không đáng kể và không ảnh hưởng đến trải nghiệm người dùng.
2. **Thời gian phản hồi của Edge Functions:**
 - `score-crypto` (mã hoá/giải mã): Thời gian phản hồi trung bình là **50-100ms**.
 - `embed` (tạo vector sở thích): Thời gian phản hồi trung bình là **200-300ms**.
 - `recommend-users` (lấy danh sách gợi ý): Thời gian phản hồi trung bình là **400-600ms** cho một tập hợp 50 người dùng.



Hình 6.3 — Biểu đồ độ trễ trung bình của các Edge Functions

Gợi ý hình: fig_rq3_latency.png - Chụp màn hình từ bảng điều khiển của Supabase về P50/P99 latency của các function

Phân tích: Độ trễ của các tác vụ mã hoá và tính toán trên thiết bị khách là rất thấp. Độ trễ lớn nhất đến từ hàm `recommend-users`, do phải thực hiện nhiều phép tính (độ tương đồng cosine cho PCA và sở thích, tính độ gần ELO) trên một tập hợp ứng viên. Mặc dù 500ms là chấp nhận được, đây là điểm cần tối ưu hóa khi lượng người dùng tăng lên. Các giải pháp có thể bao gồm sử dụng bộ nhớ đệm (caching) cho kết quả, tối ưu câu lệnh SQL, hoặc áp dụng phân mảnh địa lý như đã đề cập.

6.4.4. RQ4: Đánh giá hiệu quả bảo vệ quyền riêng tư

Việc đánh giá này mang tính định tính, dựa trên kiến trúc đã triển khai.

- **Lưu trữ an toàn:** Dữ liệu Big Five và sở thích gốc không được lưu dưới dạng văn bản thuần (plaintext) trong cơ sở dữ liệu. Thay vào đó, chúng được lưu dưới dạng `b5_cipher` và `hobbies_cipher`. Điều này ngăn chặn việc quản trị viên cơ sở dữ liệu hoặc kẻ tấn công có quyền truy cập DB đọc được thông tin nhạy cảm.
- **Giảm thiểu dữ liệu:** Việc chuyển đổi sang PCA-4 và chỉ lưu trữ vector này để so khớp giúp giảm lượng thông tin gốc cần thiết cho hệ thống gợi ý. Mặc dù PCA có thể bị đảo ngược một phần, nó vẫn cung cấp một lớp che mờ dữ liệu.
- **Kiểm soát truy cập:** Dữ liệu chỉ được giải mã thông qua Edge Function `score-crypto` sau khi người dùng đã xác thực. Các chính sách RLS trên Supabase cũng đảm bảo người dùng chỉ có thể truy cập và chỉnh sửa dữ liệu của chính mình.

Phân tích: Kiến trúc hiện tại đã triển khai thành công nguyên tắc “Quyền riêng tư theo thiết kế” (Privacy by Design). Rủi ro lớn nhất không nằm ở việc rò rỉ dữ liệu từ DB ở trạng thái nghỉ (at-rest), mà là ở việc lạm dụng quyền truy cập vào các Edge Function hoặc khóa mã hoá bị lộ. Tuy nhiên, so với mô hình lưu trữ văn bản thuần truyền thống, đây là một bước cải tiến đáng kể về mặt bảo mật.

6.5. Thảo luận và Hạn chế

6.5.1. Thảo luận

Các kết quả thực nghiệm đã xác nhận các giả thuyết thiết kế ban đầu. Hệ thống gợi ý có thể xác định chính xác sự tương đồng về tính cách, đồng thời linh

hoạt tính chỉnh kết quả dựa trên các tín hiệu phụ. Hiệu năng của hệ thống ở quy mô hiện tại là chấp nhận được, và kiến trúc bảo mật đã chứng tỏ tính hiệu quả trong việc bảo vệ dữ liệu người dùng.

6.5.2. Hạn chế

- **Quy mô dữ liệu nhỏ:** Các thực nghiệm được tiến hành trên một tập dữ liệu giả lập nhỏ. Hiệu năng và chất lượng gợi ý có thể thay đổi khi hệ thống mở rộng với hàng nghìn hoặc hàng triệu người dùng.
- **Thiếu dữ liệu thực tế (ground truth):** Việc đánh giá chất lượng gợi ý hiện tại mang tính định tính. Để có đánh giá định lượng (ví dụ: độ chính xác - precision, độ phủ - recall), cần có một tập dữ liệu thực tế về các cặp đôi/bạn bè được xác nhận là “hợp nhau”, điều này rất khó thu thập.
- **Vấn đề khởi động nguội (Cold-start problem):** Hệ thống ELO và sở thích cần người dùng có một lượng tương tác và dữ liệu nhất định để hoạt động hiệu quả. Người dùng mới sẽ chủ yếu được gợi ý dựa trên PCA.

6.6. Kết quả thực nghiệm chi tiết

Phần này trình bày các số liệu định lượng thu được từ các kịch bản kiểm thử tự động trên hệ thống thật. Các phép đo được thực hiện ở hai trạng thái: trước và sau khi áp dụng các kỹ thuật tối ưu hoá cơ sở dữ liệu.

6.6.1. 1. Hiệu năng quy trình tạo tài khoản (Upsert Pipeline)

Kịch bản kiểm thử đo độ trễ toàn trình cho việc tạo hồ sơ người dùng mới (bao gồm xác thực, mã hoá 2 lớp và lưu trữ).

Bảng 6.1 — Hiệu năng quy trình tạo tài khoản

Chỉ số	Giá trị đo được
Thời gian trung bình (Warm)	1.80 giây
Thời gian thấp nhất	1.46 giây
Thời gian cao nhất (Cold)	3.78 giây

6.6.2. 2. Phân tích kết quả gợi ý và Hiệu quả tối ưu hoá

Kịch bản kiểm thử sự thay đổi hiệu năng của hàm `recommend-users` sau khi tối ưu hoá chính sách bảo mật hàng (RLS) và bổ sung chỉ mục (Index).

Bảng 6.2 — So sánh hiệu năng gợi ý trước và sau tối ưu hoá

Trạng thái	Độ trễ phản hồi (ms)	Độ trễ xử lý tại Server (ms)
Trước tối ưu (Warm)	2640.58	2451
Sau tối ưu (Warm)	2343.39	2175
Cải thiện	11.2%	11.3%

Nhận xét: Việc chuyển đổi các chính sách RLS sang dạng truy vấn con (subquery) để tận dụng bộ nhớ đệm của PostgreSQL đã mang lại sự cải thiện rõ rệt (300ms). Mặc dù con số tuyệt đối vẫn trên 2 giây do đặc thù của hạ tầng Serverless (Free Tier), xu hướng giảm độ trễ khẳng định tính đúng đắn của phương pháp tối ưu.

Bảng xếp hạng Top 5 kết quả (Sau tối ưu):

Bảng 6.3 — Kết quả xếp hạng thực tế sau khi tối ưu hoá

Hạng	Username	Tổng điểm	PCA	ELO	Sở thích
1	Match_PCA	0.771	0.771	1220.2	0.558
2	MockUser1	0.758	0.758	1489.0	0.839
3	MockUser17	0.555	0.555	1384.0	0.074
4	MockUser6	0.476	0.476	1438.0	0.485
5	MockUser04	0.408	0.408	1474.0	0.071

6.6.3. 3. Logic cập nhật ELO thực tế

Dựa trên dữ liệu từ script benchmark, sự thay đổi điểm ELO của Viewer (Actor) và đối tượng tương tác (Target) được ghi nhận như sau:

- **Hành động Like:** Actor tăng nhẹ (1.8 điểm), Target tăng mạnh (10 điểm). Điều này minh chứng cho cơ chế khuyến khích tương tác hai chiều.
- **Hành động Skip:** Actor bị trừ điểm (10 điểm), Target không bị ảnh hưởng. Đây là cơ chế phạt hành vi lựa chọn khắt khe để cân bằng hệ sinh thái.

Độ trễ hành động (Warm): 1.0 - 1.7 giây.

Kết luận và Hướng phát triển

6.7. Tóm tắt bài toán và kết quả đạt được

Khóa luận này giải quyết bài toán xây dựng một hệ thống gợi ý kết bạn trên nền tảng di động, với trọng tâm là sự tương hợp về tính cách và yêu cầu bảo vệ quyền riêng tư cho dữ liệu người dùng. Vấn đề cốt lõi là làm thế nào để vừa có thể so khớp hiệu quả các đặc trưng tâm lý nhạy cảm, vừa giảm thiểu rủi ro rò rỉ thông tin khi lưu trữ và xử lý trên máy chủ.

Để giải quyết bài toán này, khóa luận đã đề xuất và triển khai một pipeline hoàn chỉnh với các đóng góp chính sau:

1. **Mô hình chuyển đổi tính cách trên thiết bị:** Xây dựng thành công quy trình chuyển đổi điểm tính cách Big Five sang không gian vector 4 chiều (PCA-4). Phép biến đổi này được thực hiện trực tiếp trên thiết bị của người dùng, giúp giảm chiều dữ liệu, giữ lại hơn 90% phương sai và che mờ một phần thông tin gốc trước khi gửi lên máy chủ.
2. **Cơ chế bảo mật “Privacy by Design”:** Triển khai luồng mã hóa AES-256-GCM cho dữ liệu Big Five gốc và sở thích của người dùng thông qua Edge Function. Kiến trúc này đảm bảo rằng không có dữ liệu nhạy cảm nào được lưu dưới dạng plaintext trong cơ sở dữ liệu, giúp bảo vệ thông tin người dùng ngay cả khi có sự truy cập trái phép vào DB.
3. **Hệ thống gợi ý lai (Hybrid):** Xây dựng một thuật toán xếp hạng kết hợp ba nguồn tín hiệu: sự tương đồng về tính cách (từ PCA-4), hành vi xã giao (qua điểm ELO) và sự tương đồng về sở thích (qua semantic embedding). Mô hình lai này cho phép tạo ra các gợi ý vừa có chiều sâu, vừa linh hoạt và phản ánh được hành vi thực tế của người dùng.

Qua thực nghiệm, hệ thống đã chứng minh được tính hiệu quả của các thành phần trên. Mô hình PCA-4 cho thấy khả năng xác định chính xác các cặp người dùng có tính cách tương đồng. Hệ thống gợi ý lai cho kết quả xếp hạng đa dạng

và phù hợp hơn. Đồng thời, các cơ chế bảo mật hoạt động ổn định với độ trễ chấp nhận được, không ảnh hưởng tiêu cực đến trải nghiệm người dùng.

6.8. Hạn chế của đề tài

Mặc dù đã đạt được các mục tiêu chính, khóa luận vẫn còn một số hạn chế cần được xem xét:

- **Quy mô thực nghiệm:** Các thử nghiệm được thực hiện trên tập dữ liệu giả lập với quy mô nhỏ. Hiệu năng và chất lượng của hệ thống gợi ý, đặc biệt là thành phần ELO, cần được kiểm chứng thêm với lượng người dùng thực tế lớn hơn.
- **Đánh giá chất lượng gợi ý:** Việc đánh giá hiện tại chủ yếu mang tính định tính và dựa trên các kịch bản được định sẵn. Để có một đánh giá định lượng sâu sắc hơn, cần xây dựng các bộ dữ liệu có “ground truth” hoặc tiến hành các thử nghiệm A/B testing trong môi trường thực tế.
- **Mô hình embedding sở thích:** Mô hình semantic embedding hiện tại dựa trên một dịch vụ bên ngoài. Việc tự huấn luyện (fine-tuning) một mô hình embedding trên tập dữ liệu sở thích của chính ứng dụng có thể mang lại kết quả phù hợp hơn nữa.

6.9. Hướng phát triển trong tương lai

Dựa trên các kết quả và hạn chế, có một số hướng phát triển tiềm năng cho hệ thống:

- **Tối ưu hóa hiệu năng:** Khi lượng người dùng tăng, cần áp dụng các kỹ thuật tối ưu hóa cho hàm gợi ý `recommend-users` như caching, pre-computation, và đặc biệt là geosharding để giảm không gian tìm kiếm.
- **Mở rộng mô hình gợi ý:** Có thể bổ sung thêm các nguồn tín hiệu khác vào mô hình lai, ví dụ như phân tích ẩn danh các mẫu hình tương tác hoặc phong cách giao tiếp trong tin nhắn.
- **Phân tích và giải thích kết quả:** Xây dựng các tính năng cho phép người dùng hiểu tại sao họ được gợi ý một người dùng khác (“Explainable AI”), ví dụ như “bạn và người này cùng có xu hướng hướng ngoại” hoặc “cùng yêu thích phim khoa học viễn tưởng”.

- **Bảo mật nâng cao:** Nghiên cứu khả năng áp dụng các kỹ thuật bảo mật tiên tiến hơn như Homomorphic Encryption cho một số tác vụ tính toán đơn giản trên máy chủ mà không cần giải mã dữ liệu.

Công bố liên quan

Hiện tại, các kết quả của khóa luận chưa được công bố trong các bài báo hay hội thảo khoa học.

Tài liệu tham khảo

- [1] Tupes EC, Christal RE. Recurrent personality factors based on trait ratings. *Journal of Personality* 1961;30:563–80.
- [2] John OP, Srivastava S. The Big Five trait taxonomy: History, measurement, and theoretical perspectives. *Handbook of personality: Theory and research* 1999;2:102–38.
- [3] Youyou W, Kosinski M, Stillwell D. Computer-based personality judgments are more accurate than those made by humans. *Proceedings of the National Academy of Sciences* 2015;112:1036–40.
- [4] Meng KS, Leung L. Factors influencing TikTok engagement behaviors in China: An examination of gratifications sought, narcissism, and the Big Five personality traits. *Telecommunications Policy* 2021;45:102172.
- [5] Federal Trade Commission. FTC Imposes \$5 Billion Penalty and Sweeping New Privacy Restrictions on Facebook 2019. <https://www.ftc.gov/news-events/news/press-releases/2019/07/ftc-imposes-5-billion-penalty-sweeping-new-privacy-restrictions-facebook>.
- [6] CNIL. The CNIL's restricted committee imposes a financial penalty of 50 million euros against GOOGLE LLC 2019. <https://www.cnil.fr/en/cnil-restricted-committee-imposes-financial-penalty-50-million-euros-against-google-llc>.
- [7] Automoto. Big five trait scores for 307,313 people from many different countries 2023.
- [8] NIST. Galois/Counter Mode of Operation (GCM). NIST Special Publication 800-38D 2007.
- [9] Goldberg LR. The development of markers for the Big-Five factor structure. *Psychological Assessment* 1992;4:26–42.
- [10] Manning CD, Raghavan P, Sch"utze H. *Introduction to Information Retrieval*. Cambridge University Press; 2008.

- [11] Elo AE. The Rating of Chessplayers, Past and Present. Arco Publishing; 1978.
- [12] Ashton MC, Lee K. Empirical, theoretical, and practical advantages of the HEXACO model of personality structure. *Personality and Social Psychology Review* 2007;11:150–66.
- [13] Kaggle. Big Five Personality Test 2018. <https://www.kaggle.com/datasets/tunguz/big-five-personality-test>.
- [14] Jolliffe IT. Principal Component Analysis. Springer; 2002.
- [15] Rivest RL, Shamir A, Adleman L. A method for obtaining digital signatures and public-key cryptosystems. *Communications of the ACM* 1978;21:120–6.
- [16] Provos N, Mazieres D. A Future-Adaptable Password Scheme. trong: Proceedings of the 1999 USENIX Annual Technical Conference, 1999, tr 81–92.
- [17] Gentry C. Fully homomorphic encryption using ideal lattices. trong: Proceedings of the 41st Annual ACM Symposium on Theory of Computing, 2009, tr 169–78.
- [18] Dwork C, McSherry F, Nissim K, Smith A. Calibrating noise to sensitivity in private data analysis. trong: Theory of Cryptography Conference, 2006, tr 265–84.
- [19] Reimers N, Gurevych I. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. trong: Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing, 2019, tr 3982–92.
- [20] Mikolov T, Chen K, Corrado G, Dean J. Efficient estimation of word representations in vector space. trong: International Conference on Learning Representations, 2013.

Phụ lục

A. Bộ câu hỏi Big Five (Phiên bản Tiếng Anh)

Dưới đây là danh sách đầy đủ 50 câu hỏi Big Five (IPIP-50) được sử dụng trong hệ thống.

1. I am the life of the party.
2. I feel little concern for others.
3. I am always prepared.
4. I get stressed out easily.
5. I have a rich vocabulary.
6. I don't talk a lot.
7. I am interested in people.
8. I leave my belongings around.
9. I am relaxed most of the time.
10. I have difficulty understanding abstract ideas.
11. I feel comfortable around people.
12. I insult people.
13. I pay attention to details.
14. I worry about things.
15. I have a vivid imagination.
16. I keep in the background.
17. I sympathize with others' feelings.
18. I make a mess of things.
19. I seldom feel blue.
20. I am not interested in abstract ideas.
21. I start conversations.
22. I am not interested in other people's problems.
23. I get chores done right away.
24. I am easily disturbed.

25. I have excellent ideas.
26. I have little to say.
27. I have a soft heart.
28. I often forget to put things back in their proper place.
29. I get upset easily.
30. I do not have a good imagination.
31. I talk to a lot of different people at parties.
32. I am not really interested in others.
33. I like order.
34. I change my mood a lot.
35. I am quick to understand things.
36. I don't like to draw attention to myself.
37. I take time out for others.
38. I shirk my duties.
39. I have frequent mood swings.
40. I use difficult words.
41. I don't mind being the center of attention.
42. I feel others' emotions.
43. I follow a schedule.
44. I get irritated easily.
45. I spend time reflecting on things.
46. I am quiet around strangers.
47. I make people feel at ease.
48. I am exacting in my work.
49. I often feel blue.
50. I am full of ideas.

B. Mã nguồn một số hàm quan trọng

Phần này trình bày mã nguồn của các hàm thực thi biên (Edge Functions) quan trọng và các chính sách bảo mật cơ sở dữ liệu (RLS Policies).

B.1. Mã hóa và Giải mã dữ liệu (score-crypto)

Hàm này xử lý việc mã hoá và giải mã dữ liệu nhạy cảm sử dụng thuật toán AES-256-GCM.

```
1  import { serve } from 'https://deno.land/std@0.192.0/http/
server.ts';
2  type Scores = Record<string, number>;
3  function toBytes(str: string) {
4    return new TextEncoder().encode(str);
5  }
6  function fromBase64(b64: string) {
7    return Uint8Array.from(atob(b64), (c) => c.charCodeAt(0));
8  }
9  function toBase64(bytes: ArrayBuffer | Uint8Array) {
10     const arr = bytes instanceof Uint8Array ? bytes : new
    Uint8Array(bytes);
11     let binary = '';
12     arr.forEach((b) => (binary += String.fromCharCode(b)));
13     return btoa(binary);
14  }
15  async function importKey(reqId: string) {
16     const secret = Deno.env.get('B5_ENCRYPTION_KEY');
17     if (!secret) throw new Error('Missing B5_ENCRYPTION_KEY secret');
18     const keyBytes = fromBase64(secret);
19     return crypto.subtle.importKey('raw', keyBytes, 'AES-GCM', false,
    ['encrypt', 'decrypt']);
20  }
21  async function encrypt(data: unknown, reqId: string) {
22     const key = await importKey(reqId);
23     const iv = crypto.getRandomValues(new Uint8Array(12));
24     const payload = toBytes(JSON.stringify(data));
25     const cipher = await crypto.subtle.encrypt({ name: 'AES-GCM',
    iv }, key, payload);
26     return { cipher: toBase64(cipher), iv: toBase64(iv) };
```

```

27 }
28 async function decrypt(cipherText: string, ivB64: string, reqId:
    string) {
29     const key = await importKey(reqId);
30     const cipherBytes = fromBase64(cipherText);
31     const iv = fromBase64(ivB64);
32     const plain = await crypto.subtle.decrypt({ name: 'AES-GCM',
        iv }, key, cipherBytes);
33     const decoded = new TextDecoder().decode(plain);
34     return JSON.parse(decoded);
35 }
36 serve(async (req) => {
37     // ... (Request handling logic omitted)
38 });

```

B.2. Thuật toán Gợi ý người dùng (recommend-users)

Hàm này tính toán độ tương đồng cosine trên không gian PCA-4 và vector sở thích, kết hợp điểm ELO.

```

1 // ... imports ts
2 function cosine(a: number[], b: number[]) {
3     let dot = 0, na = 0, nb = 0;
4     for (let i = 0; i < a.length; i++) {
5         dot += a[i] * b[i];
6         na += a[i] * a[i];
7         nb += b[i] * b[i];
8     }
9     const denom = Math.sqrt(na) * Math.sqrt(nb);
10    return denom === 0 ? 0 : dot / denom;
11 }
12 function eloProximity(rA: number, rB: number, sigma = 400) {
13     const diff = Math.abs(rA - rB);
14     return Math.exp(-diff / sigma);
15 }
16 serve(async (req) => {
17     // ... (Setup and data fetching)
18     // Scoring logic within the loop:
19     /*

```

```

20     let pcaSim = Math.max(0, Math.min(1, cosine(meVec, vec)));
21     if (allowElo) {
22         const prox = eloProximity(meElo, cElo);
23         // With Hobbies: PCA 50%, ELO 20%, Hobbies 30%
24         score = 0.5 * pcaSim + 0.2 * prox + 0.3 * hSim;
25     } else {
26         // Without ELO: PCA 55%, Hobbies 45%
27         score = 0.55 * pcaSim + 0.45 * hSim;
28     }
29     */
30     // ... (Sorting and pagination)
31 });

```

B.3. Cập nhật ELO và Tương tác (match-update)

Hàm xử lý like/skip, cập nhật ELO và tạo match.

```

1  const K_FACTOR = 12;
2  function expectedScore(rA: number, rB: number) {
3      return 1 / (1 + Math.pow(10, (rB - rA) / 400));
4  }
5  function clampElo(r: number) {
6      return Math.max(800, Math.min(2000, r));
7  }
8  function updateRatings(rA: number, rB: number, outcome: 'like' |
9      'skip', k = K_FACTOR) {
10     const Ea = expectedScore(rA, rB);
11     const Eb = expectedScore(rB, rA);
12     if (outcome === 'like') {
13         // Cooperative: both gain modestly toward an expected win
14         const newA = clampElo(rA + k * (1 - Ea));
15         const newB = clampElo(rB + k * (1 - Eb));
16         return { newA, newB };
17     }
18     // Skip: penalize actor only
19     const newA = clampElo(rA + k * (0 - Ea));
20     return { newA, newB: rB };
21 }
// ... (Database transaction handling)

```

B.4. Chính sách bảo mật cơ sở dữ liệu (RLS Policies)

```
1  -- Users can only read/update their own profile sql
2  create policy profiles_is_owner on public.profiles
3    for all using (auth.uid() = id) with check (auth.uid() = id);
4
5  -- Users can only see matches where they are a participant
6  create policy match_select on public.matches
7    for select using (auth.uid() = user_a or auth.uid() = user_b);
8
9  -- Only service_role (Edge Functions) can insert new matches
10 create policy match_insert on public.matches
11    for insert with check (auth.role() = 'service_role');
```

C. Mã nguồn kịch bản kiểm thử (Benchmarks)

Đây là mã nguồn của các công cụ kiểm thử tự động được sử dụng để thu thập số liệu cho Chương 6. Các thông tin nhạy cảm đã được ẩn.

C.1. Script tạo dữ liệu mẫu và đo hiệu năng Uperst (seedMockProfiles.ts)

```
1  import { createClient } from '@supabase/supabase-js'; ts
2
3  // Configuration
4  const SUPABASE_URL = '...HIDDEN...';
5  const SERVICE_KEY = '...HIDDEN...';
6  const DEFAULT_PASSWORD = '...HIDDEN...';
7
8  // ... (PCA Constants & Helpers omitted)
9
10 async function createUser(email: string, username: string, pca:
11   number[], elo: number, hobbies: string[]) {
12
13   // 1. Auth Creation
14   // ... (Auth Logic)
15
16   // 2. Encrypt Scores
```



```

17 // ... (Call Edge Function)
18 // 3. Hobbies
19 // ... (Call Edge Function)
20
21 // 4. Upsert Profile
22 const profilePayload = {
23   id: userId,
24   // ... (Payload construction)
25 };
26
27 const { error: dbError } = await
supabase.from('profiles').upsert(profilePayload);
28
29 const endTotal = performance.now();
30 const duration = endTotal - startTotal;
31 stats.push(duration); // Collect stats
32 }
33
34 async function seed() {
35   console.log('--- STARTING PERFORMANCE SEED ---');
36   // ... (Loop to create users)
37 }

```

C.2. Script kiểm thử kịch bản Viewer (benchmark_scenarios.ts)

```

1 import { createClient } from '@supabase/supabase-js';
2 import dotenv from 'dotenv';
3
4 dotenv.config();
5
6 const SUPABASE_URL = process.env.EXPO_PUBLIC_SUPABASE_URL!;
7 const SUPABASE_KEY = '...HIDDEN...';
8
9 const supabase = createClient(SUPABASE_URL, SUPABASE_KEY);
10
11 async function benchmark() {
12   console.log('\n--- SCENARIO BENCHMARK: VIEWER FLOW ---');
13

```

```

14 // 1. LOGIN
15 const tLoginStart = performance.now();
16 const { data: auth, error: authError } = await
supabase.auth.signInWithPassword({
17   email: 'viewer@test.com',
18   password: '...HIDDEN...'
19 });
20 const tLoginEnd = performance.now();
21 console.log(`[Login] Latency: ${tLoginEnd -
tLoginStart).toFixed(2)}ms`);
22
23 // 2. RECOMMENDATION (Cold/Warm)
24 const tRecStart = performance.now();
25 const { data: recData, error: recError } = await
supabase.functions.invoke('recommend-users', {
26   body: {
27     userId: auth.user.id,
28     useElo: true,
29     useHobbies: true,
30     filters: {}
31   }
32 });
33 const tRecEnd = performance.now();
34 console.log(`[Recommend] Latency: ${tRecEnd -
tRecStart).toFixed(2)}ms`);
35
36 // ... (Log Top 5 / Bottom 5)
37
38 // 3. INTERACTION (Like/Skip)
39 // ... (Call match-update Edge Function and measure time)
40 }
41
42 benchmark();

```

D. Kỹ thuật tối ưu hóa cơ sở dữ liệu

Dưới đây là mã nguồn SQL được sử dụng để tối ưu hoá hiệu năng cho các chính sách bảo mật hàng (RLS) và tăng tốc độ truy vấn thông qua chỉ mục (Index).

```

1  -- 1. Tối ưu hoá RLS bằng cách sử dụng subquery để cache
   auth.uid()
2  DROP POLICY IF EXISTS "profiles_is_owner" ON public.profiles;
3  CREATE POLICY "profiles_is_owner_optimized" ON public.profiles
4  FOR ALL USING ( id = (select auth.uid()) );
5
6  -- 2. Gộp các chính sách SELECT thừa trên bảng matches
7  DROP POLICY IF EXISTS "match_select" ON public.matches;
8  DROP POLICY IF EXISTS "realtime_matches_select" ON public.matches;
9  CREATE POLICY "matches_select_optimized" ON public.matches
10 FOR SELECT USING (
11   user_a = (select auth.uid()) OR
12   user_b = (select auth.uid())
13 );
14
15 -- 3. Bổ sung chỉ mục (Index) cho các cột lọc và liên kết quan
   trọng
16 CREATE INDEX IF NOT EXISTS idx_profiles_id ON public.profiles(id);
17 CREATE INDEX IF NOT EXISTS idx_matches_user_a ON
   public.matches(user_a);
18 CREATE INDEX IF NOT EXISTS idx_matches_user_b ON
   public.matches(user_b);
19 CREATE INDEX IF NOT EXISTS idx_profiles_gender ON
   public.profiles(gender);
20 CREATE INDEX IF NOT EXISTS idx_profiles_age_group ON
   public.profiles(age_group);

```

sql